



การวิเคราะห์และเปรียบเทียบตัวแบบอนุกรมเวลาสำหรับ
การพยากรณ์ยอดขายของบริษัท ABC จำกัด
Analysis and Comparison of Time Series Models for
Sales Forecasting of ABC Company Limited

โดย

นายธีรภัทร คำเข้าเมือง รหัสประจำตัวนิสิต 6530206108

นายธีรัช ธรรมณี รหัสประจำตัวนิสิต 6530206094

โครงการนี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตร
วิทยาศาสตรบัณฑิต (วิทยาการวิเคราะห์ข้อมูลและคณิตศาสตร์ประกันภัย)
คณะวิทยาศาสตร์ ศรีราชา
มหาวิทยาลัยเกษตรศาสตร์ วิทยาเขตศรีราชา
ปีการศึกษา 2568

ใบรับรองโครงการ
คณะวิทยาศาสตร์ ศรีราชา
ปริญญาวิทยาศาสตรบัณฑิต (วิทยาการวิเคราะห์ข้อมูลและคณิตศาสตร์ประกันภัย)

การวิเคราะห์และเปรียบเทียบตัวแบบอนุกรมเวลาสำหรับการพยากรณ์ยอดขาย
ของบริษัท ABC จำกัด
Analysis and Comparison of Time Series Models for Sales Forecasting
of ABC Company Limited

นายธีรภัทร คำเข้าเมือง รหัสประจำตัวนิสิต 6530206108

นายธีรวิช ธรรมณี รหัสประจำตัวนิสิต 6530206094

ได้รับการตรวจสอบและอนุมัติ ให้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตร

ประธานกรรมการสอบ

(ผศ.ดร.พงษ์ศักดิ์ ประกฤษศรี)

กรรมการและอาจารย์ที่ปรึกษา

(ดร.จุฬาลักษณ์ แก้วห้วงสกุล)

กรรมการและอาจารย์ที่ปรึกษา

(ดร.ณัฐนนท์ ทรงสุวรรณ)

กรรมการสอบโครงการ

(ดร.วิภาวี ดำมินเศษ)

ประธานหลักสูตร

(รศ.ณรงค์ฤทธิ์ แก้วบรรจักษ์)

ชื่อเรื่อง	การวิเคราะห์และเปรียบเทียบตัวแบบอนุกรมเวลา สำหรับการพยากรณ์ยอดขายของบริษัท ABC จำกัด
ชื่อผู้เขียน	นายธีรภัทร คำบำรุงเมือง นายธีรชัช ศรีมณี
ชื่อปริญญา	วิทยาศาสตร์บัณฑิต (วิทยาการวิเคราะห์ข้อมูลและ คณิตศาสตร์ประยุกต์)
อาจารย์ที่ปรึกษา	จุฬาลักษณ์ แก้วหวังสกุล, วท.ด.
อาจารย์ที่ปรึกษาร่วม	ณัฐธนนท์ ทรงสุวรรณ, ประ.ด.
คำสำคัญ:	อนุกรมเวลา การพยากรณ์ยอดขาย พรอเฟต ซาริแมกซ์

บทคัดย่อ

โครงการนี้มีวัตถุประสงค์เพื่อพัฒนาและเปรียบเทียบประสิทธิภาพของตัวแบบการพยากรณ์ยอดขายระหว่างตัวแบบ Prophet และตัวแบบ SARIMAX โดยใช้ข้อมูลยอดขายย้อนหลังของบริษัท ABC จำกัด ในช่วงปี ค.ศ. 2021–2024 ข้อมูลถูกจัดกลุ่มแบบรายเดือนซึ่งอยู่ในรูปแบบอนุกรมเวลา และแบ่งออกเป็นชุดข้อมูลฝึกฝน (ปี 2021-2023) และชุดข้อมูลทดสอบ (ปี 2024) เพื่อคาดการณ์แนวโน้มยอดขายในอนาคต การประเมินความแม่นยำของตัวแบบใช้ตัวชี้วัดทางสถิติได้แก่ ค่าความคลาดเคลื่อนสัมบูรณ์เฉลี่ย (MAE) รากของค่าคลาดเคลื่อนกำลังสองเฉลี่ย (RMSE) และค่าร้อยละความคลาดเคลื่อนสัมบูรณ์เฉลี่ย (MAPE) ผลการทดลองแสดงให้เห็นว่าตัวแบบ Prophet ให้ค่าความคลาดเคลื่อนต่ำกว่าตัวแบบ SARIMAX โดยมีค่า MAE เท่ากับ 181,663.86 RMSE เท่ากับ 223,727.26 และ MAPE เท่ากับ 43.55% ดังนั้นจึงสามารถสรุปได้ว่าตัวแบบ Prophet มีความเหมาะสมมากกว่าตัวแบบ SARIMAX ในการนำไปใช้ในการคาดการณ์ยอดขายของบริษัท ABC จำกัด เพื่อสนับสนุนการวางแผนเชิงกลยุทธ์และการตัดสินใจทางธุรกิจในอนาคต

Title	Analysis and Comparison of Time Series Models for Sales Forecasting of ABC Company Limited
Author	Mr.Teerapat Kambaomueng Mr.Teetouch Sornmanee
Degree	Bachelor of Science (Data Analytics and Actuarial Science)
Advisor	Julalak Kaewwangsakoon Ph.D.
Co-Advisor	Nuttanon Songsuwans Ph.D.

Keywords: Time Series, Sales Forecasting, Prophet, SARIMAX

ABSTRACT

This project aims to develop and compare the forecasting performance of two sales prediction models: Prophet and SARIMAX. The study uses historical monthly sales data from ABC Company Limited for the period 2021–2024. The data were organized as a time series and divided into a training set (2021–2023) and a testing set (2024) to forecast future sales trends. The accuracy of the models was evaluated using statistical metrics, including Mean Absolute Error (MAE), Root Mean Squared Error (RMSE), and Mean Absolute Percentage Error (MAPE). The experimental results indicate that the Prophet model achieved lower forecasting errors than the SARIMAX model, with MAE of 181,663.86, RMSE of 223,727.26, and MAPE of 43.55%. Therefore, it can be concluded that the Prophet model is more suitable than the SARIMAX model for forecasting the sales of ABC Company Limited, supporting future strategic planning and business decision-making.

กิตติกรรมประกาศ

ข้าพเจ้าขอแสดงความขอบพระคุณอย่างสูงสุดแด่ ดร.จุฬาลักษณ์ แก้วหวังสกุล อาจารย์ที่ปรึกษา โครงการงาน และ ดร.ณัฐนันท์ ทรงสุวรรณ อาจารย์ที่ปรึกษาร่วมโครงการ ที่ให้ความอนุเคราะห์ในการให้ คำแนะนำ อบรมสั่งสอน และให้แนวคิดเชิงวิชาการที่เป็นประโยชน์ตลอดระยะเวลาการดำเนินโครงการ อีกทั้ง ยังสละเวลาอันมีค่าในการตรวจสอบ แก้ไข และให้ข้อเสนอแนะที่ช่วยให้โครงการนี้มีความสมบูรณ์ยิ่งขึ้น

ข้าพเจ้าขอขอบพระคุณ ผศ.ดร.พงษ์สัณญ์ ประกฤตศรี ประธานกรรมการสอบ ที่ได้ให้คำแนะนำ อย่างละเอียดรอบคอบ ซึ่งเป็นแนวทางสำคัญในการปรับปรุงและพัฒนาโครงการให้มีความถูกต้องและ ครบถ้วนยิ่งขึ้น ขอขอบพระคุณ ดร.วิภาวี ดำมินเศษ กรรมการสอบโครงการ ที่ได้ให้ข้อเสนอแนะอันเป็น ประโยชน์ ช่วยให้ข้าพเจ้าสามารถปรับปรุงและพัฒนาโครงการให้มีความสมบูรณ์ทางวิชาการ

ข้าพเจ้าขอขอบพระคุณ บริษัท ABC จำกัด ที่ให้ความอนุเคราะห์ข้อมูลสำหรับการดำเนินโครงการครั้งนี้ ซึ่งเป็นส่วนสำคัญที่ทำให้การวิเคราะห์และการพยากรณ์ยอดขายสามารถดำเนินไปได้ อย่างสมบูรณ์

ข้าพเจ้าขอขอบพระคุณ มหาวิทยาลัยเกษตรศาสตร์ วิทยาเขตศรีราชา สำหรับการสนับสนุน ด้าน ทรัพยากรที่จำเป็น ตลอดจนความเอื้อเฟื้อสถานที่และสิ่งอำนวยความสะดวก ซึ่งมีส่วนสำคัญในการดำเนิน โครงการครั้งนี้

ธีรภัทร คำบัวเมือง

ธีธัช ศรีมณี

29 ตุลาคม พ.ศ. 2568

สารบัญ

เรื่อง	หน้า
บทคัดย่อ	I
ABSTRACT	II
กิตติกรรมประกาศ	III
สารบัญ	IV
สารบัญตาราง	VI
สารบัญภาพ	VII
บทที่ 1 บทนำ	1
1.1 ที่มาและความสำคัญของโครงการ	1
1.2 วัตถุประสงค์ของโครงการ	1
1.3 ขอบเขตของโครงการ	2
1.4 กรอบแนวคิดสำคัญของโครงการ	2
1.5 ผลที่คาดว่าจะได้รับ	3
บทที่ 2 ความรู้พื้นฐาน	4
2.1 ความรู้พื้นฐานเกี่ยวกับอนุกรมเวลา	4
2.2 ตัวแบบพรอเฟต (Prophet)	6
2.3 ตัวแบบซาริแมกซ์ (Seasonal Autoregressive Integrated Moving Average with eXogenous variables - SARIMAX)	17
2.4 ตัวชี้วัดความแม่นยำของตัวแบบ	23
บทที่ 3 วิธีดำเนินการวิจัย	25
3.1 เครื่องมือที่ใช้ในการดำเนินงาน	25
3.2 แหล่งข้อมูลที่ใช้ในการวิจัย	25
3.3 การจัดเตรียมข้อมูล	25

3.4 การเลือกตัวแบบและพยากรณ์	32
3.5 การประเมินประสิทธิภาพของตัวแบบ	35
3.6 การพยากรณ์ยอดขายล่วงหน้า	36
3.7 ฝั่งงานกระบวนการดำเนินงาน	37
บทที่ 4 ผลการวิเคราะห์ข้อมูล	38
4.1 ผลจากการพยากรณ์ที่ได้จากตัวแบบ Prophet	38
4.2 ผลจากการพยากรณ์ที่ได้จากตัวแบบ SARIMAX	40
4.3 ผลการประเมินประสิทธิภาพของตัวแบบ (Model Evaluation Results)	43
4.4 สรุปผลการวิเคราะห์	43
บทที่ 5 สรุปผลการวิจัย	46
5.1 สรุปผลการวิจัย	46
5.2 ข้อจำกัดของการวิจัย	46
5.3 ข้อเสนอแนะ	47
บรรณานุกรม	48
ภาคผนวก	50
ภาคผนวก ก	51
ภาคผนวก ข	57
ประวัติการศึกษา	63

สารบัญตาราง

ตารางที่	หน้า
ตาราง 2.1 ค่าพารามิเตอร์ของตัวแบบ Prophet	16
ตาราง 2.2 ค่าพารามิเตอร์ของตัวแบบ SARIMAX	21
ตาราง 3.1 ข้อมูลยอดขายบริษัท ABC	25
ตาราง 3.2 ข้อมูลเชิงสถิติของยอดขาย	26
ตาราง 3.3 ข้อมูลเชิงสถิติหลังตัดค่าผิดปกติ	27
ตาราง 3.4 ข้อมูลหลังจากการจัดกลุ่ม	28
ตาราง 3.5 ข้อมูลเชิงสถิติหลังการจัดกลุ่มข้อมูล	28
ตาราง 3.6 ค่าพารามิเตอร์ที่กำหนดของตัวแบบ Prophet	33
ตาราง 3.7 ค่าพารามิเตอร์ที่กำหนดของตัวแบบ SARIMAX	33
ตาราง 3.8 ขั้นตอนการพยากรณ์ยอดขายด้วยตัวแบบ Prophet และ SARIMAX	34
ตาราง 4.1 ค่าการประเมินประสิทธิภาพของตัวแบบ Prophet เพิ่มตัวแปรภายนอก	38
ตาราง 4.2 ค่าการประเมินประสิทธิภาพที่น้อยที่สุดของตัวแบบ Prophet เมื่อใช้ร่วมกับตัวแปรภายนอก	39
ตาราง 4.3 ค่าผลลัพธ์จากการประมาณค่าตัวแบบหลายชุดที่ได้จากกระบวนการ การค้นหาพารามิเตอร์อัตโนมัติ	41
ตาราง 4.4 ค่าจากการประเมินประสิทธิภาพของตัวแบบ SARIMAX เพิ่มตัวแปรภายนอก	42
ตาราง 4.5 ค่าการประเมินประสิทธิภาพที่น้อยที่สุดของตัวแบบ SARIMAX เมื่อใช้ร่วมกับตัวแปรภายนอก	42
ตาราง 4.6 ผลการเปรียบเทียบของตัวแบบ Prophet และ SARIMAX	43

สารบัญภาพ

ภาพที่	หน้า
ภาพที่ 1.1 กรอบแนวคิดสำคัญของโครงการ	2
ภาพที่ 2.1 กราฟอนุกรมเวลาแบบผลบวก	5
ภาพที่ 2.2 กราฟอนุกรมเวลาแบบผลคูณ	6
ภาพที่ 2.3 กราฟตัวอย่างฟังก์ชันแนวโน้มเชิงเส้นแบบเป็นช่วง	9
ภาพที่ 2.4 กราฟตัวอย่างฟังก์ชันแนวโน้มแบบโลจิสติก	11
ภาพที่ 2.5 กราฟตัวอย่างฟังก์ชันฤดูกาล	13
ภาพที่ 2.6 กราฟตัวอย่างฟังก์ชันวันหยุด	14
ภาพที่ 3.1 กราฟองค์ประกอบของอนุกรมเวลาแบบผลบวก	29
ภาพที่ 3.2 กราฟองค์ประกอบของอนุกรมเวลาแบบผลคูณ	30
ภาพที่ 3.3 แผนผังกระบวนการดำเนินงาน	37
ภาพที่ 4.1 กราฟผลการทำนายของตัวแบบ Prophet	40
ภาพที่ 4.2 กราฟผลการทำนายของตัวแบบ SARIMAX	43
ภาพที่ 4.3 กราฟผลการพยากรณ์ยอดขายล่วงหน้าของตัวแบบ Prophet	45

บทที่ 1 บทนำ

1.1 ที่มาและความสำคัญของโครงการ

การพยากรณ์ยอดขาย (Sales Forecasting) คือ กระบวนการคาดการณ์ยอดขายในอนาคต โดยอาศัยข้อมูลในอดีตและปัจจัยแวดล้อมมาวิเคราะห์ เพื่อสร้างความเป็นของยอดขายในช่วงเวลาข้างหน้า ซึ่งเป็นเครื่องมือสำคัญในการวางแผนเชิงกลยุทธ์ของธุรกิจ ทั้งในด้านการผลิต การจัดการสินค้าคงคลัง การบริหารทรัพยากรทางการเงิน และการวางแผนบุคลากรอย่างมีประสิทธิภาพ อีกทั้งยังช่วยให้ฝ่ายการตลาดสามารถกำหนดกลยุทธ์และช่วงเวลาในการจัดกิจกรรมส่งเสริมการขายได้เหมาะสมกับความต้องการของตลาด ปัจจุบันการแข่งขันทางธุรกิจมีความเข้มข้นมากขึ้น ความสามารถในการคาดการณ์แนวโน้มยอดขายได้อย่างแม่นยำจึงมีความสำคัญต่อการตัดสินใจในเชิงกลยุทธ์ขององค์กร การนำเทคนิคการวิเคราะห์ข้อมูลอนุกรมเวลามาใช้ในกระบวนการพยากรณ์สามารถช่วยให้ประมาณแนวโน้มและฤดูกาลของยอดขายได้ละเอียดและแม่นยำยิ่งขึ้น (Hyndman, Athanasopoulos, 2021) ซึ่งจะช่วยให้องค์กรสามารถวางแผนเชิงกลยุทธ์ด้านการผลิตและการตลาดได้อย่างมีประสิทธิภาพมากยิ่งขึ้น

ในด้านเทคนิคการวิเคราะห์ข้อมูลอนุกรมเวลา การเลือกใช้ตัวแบบที่เหมาะสมกับลักษณะของข้อมูลเป็นปัจจัยสำคัญที่ส่งผลต่อความแม่นยำของผลลัพธ์ ตัวแบบ Prophet มีจุดเด่นด้านความยืดหยุ่นในการจัดการกับข้อมูลที่มีแนวโน้มและฤดูกาล โดยไม่จำเป็นต้องปรับค่าพารามิเตอร์มากนัก เหมาะสำหรับข้อมูลที่มีความซับซ้อนและไม่เป็นเชิงเส้น (Sharma, Bhalla, Ganesan, 2022) ในขณะที่ตัวแบบ SARIMAX ซึ่งเป็นตัวแบบเชิงสถิติแบบดั้งเดิม มีความแม่นยำสูงในการวิเคราะห์ข้อมูลที่มีลักษณะเป็นฤดูกาล และสามารถ(เพิ่มตัวแปรภายนอกเพื่อเพิ่มประสิทธิภาพในการพยากรณ์) (Rupika Priyatham, Ramasree, 2023)

โครงการนี้มีวัตถุประสงค์เพื่อสร้างตัวแบบในการพยากรณ์ยอดขายจากข้อมูลยอดขายย้อนหลังด้วยเทคนิคอนุกรมเวลา โดยใช้ตัวแบบ Prophet และตัวแบบ SARIMAX จากนั้นจะทำการประเมินประสิทธิภาพของแต่ละตัวแบบ และนำตัวแบบที่มีประสิทธิภาพมากที่สุดมาพยากรณ์ยอดขาย

1.2 วัตถุประสงค์ของโครงการ


1. เพื่อสร้างตัวแบบสำหรับพยากรณ์ยอดขายโดยใช้ Prophet และ SARIMAX
2. เพื่อเปรียบเทียบประสิทธิภาพของตัวแบบ Prophet และ SARIMAX
3. เพื่อพยากรณ์ยอดขายล่วงหน้า และวิเคราะห์แนวโน้มของยอดขายในอนาคต

1.3 ขอบเขตของโครงการ

โครงการนี้มุ่งเน้นการศึกษาประสิทธิภาพของตัวแบบการพยากรณ์ยอดขายโดยใช้ข้อมูลยอดขายย้อนหลังจากบริษัท ABC จำกัด ระหว่างปี 2021 ถึงปี 2024 ซึ่งมีข้อมูลทั้งสิ้น 4,500 รายการ จากข้อมูลทั้งหมดที่มี 3 ตัวแปร ได้แก่ รหัสใบเสร็จ (doc_id) วันที่ (date) และยอดขายรวมสุทธิ (grandtotal) สำหรับการสร้างตัวแบบ

ข้อมูลถูกแบ่งออกเป็น 2 ชุด ประกอบด้วย ชุดข้อมูลฝึกสอน (Training Set) ครอบคลุมปี 2021 ถึงปี 2023 และชุดข้อมูลทดสอบ (Test Set) ในปี 2024 และในการประเมินประสิทธิภาพของตัวแบบ ได้ใช้ตัวชี้วัดทางสถิติ 3 ตัว ได้แก่ ค่าความคลาดเคลื่อนสัมบูรณ์เฉลี่ย (MAE) รากของค่าคลาดเคลื่อนกำลังสองเฉลี่ย (RMSE) และค่าร้อยละความคลาดเคลื่อนสัมบูรณ์เฉลี่ย (MAPE)

1.4 กรอบแนวคิดสำคัญของโครงการ



ภาพที่ 1.1 กรอบแนวคิดสำคัญของโครงการ

1.5 ผลที่คาดว่าจะได้รับ

1. ได้ตัวแบบที่เหมาะสมสำหรับการพยากรณ์ยอดขายสินค้า
2. ได้แนวโน้มของยอดขายในอนาคต

บทที่ 2 ความรู้พื้นฐาน

2.1 ความรู้พื้นฐานเกี่ยวกับอนุกรมเวลา

ข้อมูลอนุกรมเวลา คือ ชุดข้อมูลเชิงปริมาณที่ถูกจัดเก็บอย่างต่อเนื่องตามลำดับเวลา เช่น รายวัน รายเดือน และรายปี โดยแต่ละค่าจะมีความสัมพันธ์กับค่าก่อนหน้าและหลังจากนั้นในเชิงเวลา (Illukkumbura, 2021) ข้อมูลประเภทนี้มีความสำคัญในการวิเคราะห์แนวโน้มและการพยากรณ์ เนื่องจากช่วยให้สามารถคาดการณ์พฤติกรรมในอนาคตได้จากรูปแบบในอดีต (Hyndman, Athanasopoulos, 2021)

2.1.1 องค์ประกอบของข้อมูลอนุกรมเวลา

ข้อมูลอนุกรมเวลาสามารถแยกออกเป็นองค์ประกอบหลัก 4 ส่วน ได้แก่

T : แนวโน้ม (Trend) คือ รูปแบบการเปลี่ยนแปลงของข้อมูลในระยะยาว ข้อมูลอาจเพิ่มขึ้น ลดลง หรือคงที่ เช่น ยอดขายของสมาร์ทโฟนรุ่นใหม่เพิ่มขึ้นอย่างต่อเนื่องในช่วง 3 เดือนแรก หลังจากเปิดตัว

S : ฤดูกาล (Seasonality) คือ รูปแบบการเปลี่ยนแปลงของข้อมูลที่เกิดขึ้นซ้ำอย่างสม่ำเสมอในช่วงเวลาที่แน่นอน เช่น รายเดือน รายไตรมาส หรือรายปี ลักษณะดังกล่าวมักเกิดจากปัจจัยตามฤดูกาล เช่น ยอดขายเครื่องปรับอากาศที่เพิ่มขึ้นในช่วงเดือนเมษายนถึงพฤษภาคมของทุกปี

C : รอบวัฏจักร (Cyclic) คือ รูปแบบการเปลี่ยนแปลงของข้อมูลที่เกิดขึ้นเป็นรอบ ๆ ในระยะเวลาที่ยาวกว่า “ฤดูกาล” และไม่ได้เกิดซ้ำตามช่วงเวลาที่แน่นอน เช่น การเปลี่ยนแปลงของยอดขายที่สัมพันธ์กับภาวะเศรษฐกิจ การขยายตัวของตลาด หรือวิกฤตทางการเงิน ซึ่งอาจใช้เวลาหลายปีจึงจะครบหนึ่งรอบวัฏจักร

I : ความแปรปรวนแบบสุ่ม (Irregularity) คือ การเปลี่ยนแปลงที่เกิดขึ้นโดยไม่สามารถคาดการณ์ได้และไม่มีรูปแบบที่ชัดเจน มักเกิดจากเหตุการณ์ที่ไม่คาดคิด เช่น ภัยธรรมชาติ การระบาดของโรค หรือการประท้วงหยุดงาน


จากองค์ประกอบของอนุกรมเวลาข้างต้น จะสามารถแสดงรูปแบบของข้อมูลเวลาได้ 2 รูปแบบดังต่อไปนี้

1.) แบบผลบวก (Additive Model)

อนุกรมเวลาแบบผลบวกเป็นรูปแบบที่กำหนดให้ค่าของอนุกรมเวลาเป็นผลรวมขององค์ประกอบต่าง ๆ ดังนี้

$$Y = T + S + C + I$$

อนุกรมเวลาแบบบวกใช้เมื่อแต่ละองค์ประกอบส่งผลต่อข้อมูลในลักษณะการบวกเพิ่ม คือความผันผวนของฤดูกาลและความไม่แน่นอนจะมีขนาดคงที่ ไม่ขึ้นกับระดับของข้อมูลในช่วงเวลาใด ๆ (Bauer, 2020)



ภาพที่ 2.1 กราฟอนุกรมเวลาแบบผลบวก

หมายเหตุ.กราฟแสดงความสัมพันธ์ของอนุกรมเวลาแบบผลบวก. จาก “Automated Hybrid Time Series Forecasting Design,” โดย Eismann, S., 2022, *University of Würzburg*

สืบค้นเมื่อ 1 ตุลาคม 2568


จากภาพที่ 2.1 แสดงอนุกรมเวลาที่มีลักษณะของความผันผวนตามฤดูกาลคงที่ตลอดเวลา โดยค่าฤดูกาลไม่เปลี่ยนแปลงตามระดับของข้อมูลหลักคือเมื่อระดับของข้อมูลเพิ่มขึ้นหรือลดลง ขนาดของฤดูกาลยังคงเท่าเดิม ซึ่งเป็นคุณลักษณะเฉพาะของตัวแบบอนุกรมเวลาผลบวกที่ส่วนประกอบของอนุกรมเวลาที่มีความสัมพันธ์ในลักษณะผลบวก

2.) แบบผลคูณ (Multiplicative Model)

อนุกรมเวลาแบบผลคูณเป็นรูปแบบที่กำหนดให้ค่าของอนุกรมเวลาเป็นผลคูณขององค์ประกอบต่าง ๆ ดังนี้

$$Y = T \times S \times C \times I$$

อนุกรมเวลาแบบผลคูณใช้เมื่อแต่ละองค์ประกอบของข้อมูลส่งผลในเชิงสัดส่วนต่อกัน กล่าวคือ เมื่อค่าข้อมูลหลักมีการเปลี่ยนแปลง ขนาดของฤดูกาลหรือความผันผวนก็จะเปลี่ยนแปลงตามไปด้วย เช่น หากยอดขายมีแนวโน้มเพิ่มขึ้น ความแตกต่างระหว่างช่วงฤดูกาลสูงสุดและต่ำสุดก็จะขยายมากขึ้นตามไปด้วย (Bauer, 2020)



ภาพที่ 2.2 กราฟอนุกรมเวลาแบบผลคูณ

หมายเหตุ.กราฟแสดงความสัมพันธ์ของอนุกรมเวลาแบบผลคูณ. จาก “Automated Hybrid Time Series Forecasting Design,” โดย Eismann, S., 2022, *University of Würzburg*

สืบค้นเมื่อ 1 ตุลาคม 2568

จากภาพที่ 2.2 แสดงอนุกรมเวลาที่มีความผันผวนของฤดูกาลมีการเปลี่ยนแปลงตามระดับของข้อมูลหลัก โดยเมื่อค่าของอนุกรมเวลาเพิ่มสูงขึ้นความแปรปรวนของฤดูกาลก็เพิ่มขึ้นตามไปด้วย แสดงให้เห็นถึงความสัมพันธ์ในแบบคูณระหว่างส่วนประกอบของอนุกรมเวลา

ในกระบวนการวิเคราะห์และพยากรณ์ข้อมูลอนุกรมเวลา ข้อมูลมักมีลักษณะเปลี่ยนแปลงไปตามเวลา ทั้งในด้านแนวโน้ม ฤดูกาล หรือความผันผวนที่เพิ่มหรือลดลงตามช่วงเวลา ทำให้ข้อมูลบางชุดอาจมีความไม่คงที่ (Non-stationarity) ซึ่งหมายถึงค่าทางสถิติ เช่น ค่าเฉลี่ยหรือความแปรปรวน อาจเปลี่ยนแปลงเมื่อเวลาผ่านไป การทำความเข้าใจลักษณะเหล่านี้ของข้อมูลเป็นสิ่งสำคัญในการเลือกและปรับใช้ตัวแบบที่เหมาะสมกับลักษณะของข้อมูลอนุกรมเวลา เพื่อเพิ่มความแม่นยำในการพยากรณ์ (Hyndman, Athanasopoulos, 2021)

โดยในโครงการนี้ ได้เลือกใช้ตัวแบบการพยากรณ์ข้อมูลอนุกรมเวลาจำนวน 2 ตัวแบบ ได้แก่ Prophet และ SARIMAX ในการพยากรณ์ยอดขาย รายละเอียดของแต่ละตัวแบบมีดังนี้

2.2 ตัวแบบพรอเฟต (Prophet)

Prophet ถูกพัฒนาโดย Taylor และ Letham (2018) เป็นตัวแบบการพยากรณ์ที่ได้รับความนิยมอย่างแพร่หลายในงานวิเคราะห์ข้อมูลอนุกรมเวลา โดยถูกออกแบบมาให้ใช้งานง่าย และสามารถรองรับข้อมูลที่มีแนวโน้มและฤดูกาลได้อย่างชัดเจน (Brykin, 2024) จุดเด่นของ Prophet คือความสามารถในการรองรับข้อมูลที่สูญหาย (missing values) และข้อมูลผิดปกติ (outliers) ได้ในระดับหนึ่งโดยไม่ทำให้ผลลัพธ์บิดเบือน อีกทั้งยังสามารถสามารถระบุวันหยุดหรือเหตุการณ์สำคัญที่

ต้องการให้ตัวแบบพิจารณา นอกจากนี้ Prophet ยังมีความยืดหยุ่นในการกำหนดรูปแบบฤดูกาล ให้เหมาะสมกับข้อมูล (Sharma, Bhalla, Ganesan, 2022)

ตัวแบบ Prophet ประกอบด้วย 4 องค์ประกอบหลัก (Huang, 2025) ดังสมการต่อไปนี้

$$y(t) = g(t) + s(t) + h(t) + \varepsilon_t$$

โดยที่

$g(t)$ คือ ฟังก์ชันของแนวโน้ม ณ เวลา t

$s(t)$ คือ ฟังก์ชันของฤดูกาล ณ เวลา t

$h(t)$ คือ ฟังก์ชันวันหยุด ณ เวลา t เช่น วันหยุดนักขัตฤกษ์หรือช่วงโปรโมชั่น

ε_t คือ ค่าความคลาดเคลื่อน ณ เวลาที่ t

ในกรณีที่มีการเพิ่มตัวแปรภายนอกเข้ามาเป็นตัวแปรอิสระ เพื่อช่วยอธิบายความแปรผันของตัวแปรตาม ซึ่งตัวแปรภายนอกเหล่านี้มักเป็นปัจจัยที่มีอิทธิพลต่อยอดขาย เช่น ภาวะเศรษฐกิจ กิจกรรมทางการตลาด หรือปัจจัยแวดล้อมอื่น ๆ การนำตัวแปรดังกล่าวเข้ามาประกอบการวิเคราะห์ จะช่วยเพิ่มความสามารถและประสิทธิภาพของตัวแบบในการพยากรณ์ให้แม่นยำมากยิ่งขึ้น โดยสามารถเขียนสมการได้ดังนี้

$$y(t) = g(t) + s(t) + h(t) + \beta X(t) + \varepsilon_t$$

โดยที่

$X(t)$ คือ ค่าของตัวแปรภายนอก ณ เวลา t

β คือ ค่าสัมประสิทธิ์ที่แสดงผลกระทบของ $X(t)$

กรณีใส่ตัวแปรภายนอกมากกว่า 1 ตัว เช่น $X_1, X_2, \dots, X_k$ จะได้สมการในรูป

$$y(t) = g(t) + s(t) + h(t) + \vec{\beta}^T \vec{X}(t) + \varepsilon_t$$

โดยที่

$\bar{X}(t)$ คือ เวกเตอร์ของค่าตัวแปรภายนอก ณ เวลา t

$\bar{\beta}$ คือ เวกเตอร์ของค่าสัมประสิทธิ์ที่แสดงผลกระทบของแต่ละตัวแปรภายนอก

$$\text{โดย } \bar{X}(t) = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_k \end{bmatrix} \text{ และ } \bar{\beta}(t) = \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{bmatrix}$$

จากสมการข้างต้น จะเห็นว่าตัวแบบ Prophet แบ่งองค์ประกอบหลักออกเป็นหลายส่วน โดยแต่ละส่วนทำหน้าที่อธิบายลักษณะเฉพาะของข้อมูลที่แตกต่างกันเพื่อให้เข้าใจหลักการทำงานของตัวแบบได้ชัดเจน จึงแสดงรายละเอียดของแต่ละองค์ประกอบได้ดังนี้

1.) ฟังก์ชันแนวโน้ม (Trend Function)

ตัวแบบ Prophet ใช้ฟังก์ชันแนวโน้มอยู่ 2 รูปแบบหลัก คือ ฟังก์ชันแนวโน้มเชิงเส้นแบบเป็นช่วง และฟังก์ชันแนวโน้มแบบโลจิสติก ซึ่งถูกออกแบบมาเพื่อจำลองการเติบโตของข้อมูลอนุกรมเวลาที่มีรูปแบบการเปลี่ยนแปลงที่ไม่เป็นเส้นตรง

1.1) ฟังก์ชันแนวโน้มเชิงเส้นแบบเป็นช่วง (Piecewise Linear Function)

ตัวแบบนี้กำหนดให้แนวโน้มมีลักษณะเป็นฟังก์ชันเชิงเส้นแบบเป็นช่วง ซึ่งสามารถปรับความชันของเส้นแนวโน้มได้เมื่อเกิดจุดเปลี่ยนแนวโน้มเพื่อให้ตัวแบบสามารถรองรับการเปลี่ยนแปลงของทิศทางข้อมูลได้อย่างยืดหยุ่น สมการของแนวโน้มเชิงเส้นแบบเป็นช่วงสามารถแสดงได้ดังนี้

$$g(t) = \left(k + \sum_{j=1}^J \delta_j 1_{\{t > S_j\}} \right) t + \left(m - \sum_{j=1}^J \delta_j S_j \right)$$

โดยที่

k คือ ความชันเริ่มต้นของเส้นแนวโน้ม แสดงอัตราการเปลี่ยนแปลงของแนวโน้มก่อนถึงจุดเปลี่ยนแนวโน้มแรก ซึ่งกำหนดให้เป็นแนวโน้มเริ่มต้นของข้อมูล


m คือ ส่วนตัดเริ่มต้นของเส้นแนวโน้ม

J คือ จำนวนจุดเปลี่ยนแนวโน้มทั้งหมด

S_j คือ ตำแหน่งเวลาที่เกิดจุดเปลี่ยนแนวโน้ม (Trend Changepoints) หมายถึงเวลาที่ความชันของแนวโน้มสามารถเปลี่ยนได้ ซึ่ง $j = 1, 2, \dots, J$ เป็นดัชนีเรียงลำดับแต่ละจุดเปลี่ยน

δ_j คือ ขนาดการเปลี่ยนแปลงของความชันที่จุดเปลี่ยนแนวโน้ม S_j แสดงว่าที่จุดเปลี่ยนแต่ละจุด ความชันจะเปลี่ยนไปเท่าไร

$1_{\{t > S_j\}}$ คือ ฟังก์ชันบ่งชี้ โดยจะมีค่าเท่ากับ 1 เมื่อเวลา $t > S_j$ และมีค่าเท่ากับ 0 เมื่อ $t \leq S_j$



ภาพที่ 2.3 กราฟตัวอย่างฟังก์ชันแนวโน้มเชิงเส้นแบบเป็นช่วง

จากภาพที่ 2.3 เป็นกราฟแสดงฟังก์ชันแนวโน้มเชิงเส้นแบบเป็นช่วงซึ่งประกอบด้วยความชันเริ่มต้น และค่าตัดแกน โดยความชันของเส้นแนวโน้มจะมีการปรับเปลี่ยนเมื่อเกิดจุดเปลี่ยนแนวโน้มที่เวลา S_j แต่ละจุดส่งผลให้ความชันเพิ่มขึ้นหรือลดลงตามค่าพารามิเตอร์ δ_j ดังแสดงด้วยเส้นประในรูป

Prophet การสร้างตัวแบบจะเริ่มจากการกำหนดจุดเปลี่ยนแนวโน้มที่อาจเกิดขึ้นในข้อมูล ซึ่งโดยค่าเริ่มต้นจะวางในช่วงประมาณ 80% แรกของชุดข้อมูล จากนั้นตัวแบบจะประเมินและเลือกเฉพาะจุดเปลี่ยนที่มีผลต่อแนวโน้มจริง ๆ มาใช้ในการสร้างเส้นแนวโน้ม ทำให้เส้นแนวโน้มสะท้อนพฤติกรรมของข้อมูลได้อย่างแม่นยำ จุดเด่นคือ Prophet ทำขั้นตอนนี้โดยอัตโนมัติ ผู้ใช้ไม่จำเป็นต้องระบุจุดเปลี่ยนด้วยตัวเอง แต่สามารถปรับพารามิเตอร์เพื่อกำหนดจำนวนหรือความถี่ของจุดเปลี่ยนได้

การเปลี่ยนแปลงของความชันในแต่ละจุดถูกกำกับด้วยการแจกแจงแบบ Laplace โดยกำหนดว่า

$$\delta_j \sim \text{Laplace}(0, \tau)$$

โดยที่ δ_j คือ ค่าการเปลี่ยนแปลงของความชันที่จุดเปลี่ยนที่ตำแหน่ง S_j และ τ ทำหน้าที่เป็นไฮเปอร์พารามิเตอร์ที่ควบคุมขนาดของการเปลี่ยนแปลง หาก τ มีค่าน้อย การเปลี่ยนแปลงของความชันจะถูกจำกัด ทำให้แนวโน้มมีความราบเรียบมากขึ้น

1.2) ฟังก์ชันแนวโน้มแบบโลจิสติก (Logistic growth)

นอกจากการใช้ฟังก์ชันเชิงเส้นในการอธิบายแนวโน้มของข้อมูลแล้ว ตัวแบบ Prophet ยังสามารถใช้ ฟังก์ชันแนวโน้มแบบโลจิสติก เพื่อจำลองแนวโน้มของข้อมูลที่มีขีดจำกัดของการเติบโต หรือมีลักษณะการเติบโตแบบอิ่มตัว (saturation) ได้อย่างเหมาะสม โดยแนวโน้มดังกล่าวมักปรากฏในกรณีที่ข้อมูลมีค่าเพิ่มขึ้นในช่วงแรกและค่อย ๆ ลดอัตราการเติบโตลงเมื่อเข้าใกล้ค่าขีดสูงสุด เช่น ปริมาณยอดขายในตลาดที่ถึงจุดอิ่มตัว หรือจำนวนผู้ใช้งานที่ไม่สามารถเติบโตได้เกินกว่าขีดจำกัดของระบบ ฟังก์ชันแนวโน้มแบบโลจิสติกสามารถเขียนได้ดังนี้

$$g(t) = \frac{C}{1 + e^{-k(t-m)}}$$


โดยที่

C คือ ค่าสูงสุดของข้อมูล หรือค่าสูงสุดที่แนวโน้มสามารถไปถึงได้

k คือ ความชันของแนวโน้ม

m คือ จุดกึ่งกลาง (Inflection point) หรือจุดที่ค่าของฟังก์ชันเท่ากับ $\frac{C}{2}$

การใช้ฟังก์ชันแนวนุ่มแบบโลจิสติกเหมาะสำหรับข้อมูลที่มีขอบเขตจำกัด เช่น จำนวนผู้ใช้สูงสุด เพราะจำเป็นต้องกำหนดขีดจำกัดบนและขีดจำกัดล่างให้กับตัวแบบ



ภาพที่ 2.4 กราฟตัวอย่างฟังก์ชันแนวนุ่มแบบโลจิสติก

จากภาพที่ 2.4 เป็นกราฟแสดงฟังก์ชันแนวนุ่มแบบโลจิสติกซึ่งเป็นแบบจำลองการเติบโตที่มีลักษณะเริ่มช้าในช่วงต้น จากนั้นเพิ่มขึ้นด้วยอัตราที่รวดเร็ว และชะลอตัวเมื่อเข้าใกล้ค่าความจุสูงสุดของระบบ จากกราฟพบว่า เมื่อ t ใกล้ค่า m เส้นโค้งจะเป็นช่วงที่มีอัตราการเปลี่ยนแปลงสูงที่สุด และเมื่อ t มีค่ามากขึ้นจนเข้าใกล้ระดับ C อัตราการเติบโตจะลดลงอย่างต่อเนื่อง ทำให้เส้นโค้งเข้าใกล้เส้นระดับอย่างช้า ๆ

2.) ฟังก์ชันฤดูกาล (Seasonality Function)

ตัวแบบ Prophet สามารถจำลองรูปแบบการเปลี่ยนแปลงที่เกิดขึ้นซ้ำตามรอบเวลา หรือที่เรียกว่าฤดูกาลได้ด้วย โดย Prophet ใช้วิธีการประมาณฟังก์ชันฤดูกาลด้วยอนุกรมฟูเรียร์ (Fourier Series) เพื่อจำลองความแปรผันที่เกิดขึ้นในช่วงเวลาเท่ากัน เช่น รอบสัปดาห์ รอบเดือน หรือรอบปี การนำอนุกรมฟูเรียร์มาช่วยให้ตัวแบบสามารถจับลักษณะของความผันผวนที่ซับซ้อนได้ดียิ่งขึ้น

ฟังก์ชันฤดูกาลสามารถเขียนได้ดังนี้

$$s(t) = \sum_{n=1}^N \left(a_n \cos\left(\frac{2\pi nt}{P}\right) + b_n \sin\left(\frac{2\pi nt}{P}\right) \right)$$

โดยที่

N คือ จำนวนพจน์ของฟูรีเยร์ที่ใช้


P คือ ค่าสำหรับการพิจารณาฤดูกาล เช่น $P=7$ สำหรับรายสัปดาห์, $P=365.25$ สำหรับรายปี

a_n, b_n คือ ค่าสัมประสิทธิ์ของอนุกรมฟูรีเยร์ที่ประมาณจากข้อมูล

สำหรับปัญหาที่ตัวแบบเรียนรู้รูปแบบฤดูกาลมากเกินไป ตัวแบบอาจพยายามอธิบายความผันผวนเล็ก ๆ ที่เกิดจากความบังเอิญในข้อมูล ทำให้ผลการพยากรณ์ไม่แม่นยำ เพื่อป้องกันปัญหานี้ Prophet จึงกำหนดสิ่งที่เรียกว่า ข้อจำกัดล่วงหน้า (prior) ให้กับ a_n, b_n เพื่อควบคุมไม่ให้ตัวแบบปรับค่าฤดูกาลได้อย่างอิสระเกินไป

ตัวแปรสำคัญที่ใช้ควบคุมระดับความเข้มของข้อจำกัดนี้คือ ไฮเปอร์พารามิเตอร์ σ (sigma) ซึ่งทำหน้าที่เป็นตัวกำหนดว่าตัวแบบจะยืดหยุ่นต่อการเปลี่ยนแปลงของฤดูกาลมากน้อยเพียงใด หากค่า σ น้อย ตัวแบบจะไม่ตอบสนองต่อความผันผวนเล็กน้อยในข้อมูล หากค่า σ มาก ตัวแบบจะยอมให้กราฟฤดูกาลสามารถแกว่งตัวตามข้อมูลได้มากขึ้น

ดังนั้น การกำหนดค่าพารามิเตอร์ σ ที่เหมาะสมจึงมีความสำคัญ เพราะช่วยให้ตัวแบบสามารถอธิบายรูปแบบฤดูกาลได้อย่างสมดุลคือ ไม่เรียบเกินไปจนพลาดแนวโน้มจริง และไม่ละเอียดเกินไปจนติดกับความผันผวนชั่วคราวของข้อมูล



ภาพที่ 2.5 กราฟตัวอย่างฟังก์ชันฤดูกาล

จากภาพที่ 2.5 เป็นกราฟแสดงตัวอย่างฟังก์ชันฤดูกาลซึ่งสร้างขึ้นจากอนุกรมฟูเรียร์ เพื่อจำลองความผันผวนแบบวัฏจักรตามรอบเวลา โดยกำหนดให้ช่วงฤดูกาลมีรอบเวลา $P=12$ และใช้องค์ประกอบฟูเรียร์ที่ $N=3$ เพื่อให้สามารถอธิบายรูปแบบการแกว่งของข้อมูลที่ซับซ้อนได้มากขึ้น จากกราฟพบว่ารูปแบบจะมีการขึ้นลงซ้ำเป็นคาบทุก 12 เดือน แสดงถึงฤดูกาลรายปี และความโค้งของฟังก์ชันจะเปลี่ยนแปลงไปตามสัมประสิทธิ์ในแต่ละพจน์

3.) ฟังก์ชันวันหยุด (Holiday effects Function)

ในการพยากรณ์ข้อมูลอนุกรมเวลามักพบว่าช่วงวันหยุด มีพฤติกรรมแตกต่างจากวันทำงาน เช่น ยอดขายอาจเพิ่มขึ้นหรือลดลงกว่าปกติ ดังนั้นเพื่อให้ตัวแบบสามารถจับผลกระทบของวันหยุดได้อย่างแม่นยำ จึงมีการเพิ่มฟังก์ชันวันหยุดเข้ามาในตัวแบบ เพื่อระบุว่าช่วงเวลาใดเป็นวันหยุด และวันหยุดแต่ละวันส่งผลต่อค่าพยากรณ์มากน้อยเพียงใด กำหนดให้ H เป็นเซตของวันหยุด โดยที่ $H = \{H_1, H_2, \dots, H_J\}$ ซึ่งฟังก์ชันวันหยุดสามารถเขียนได้ดังนี้

$$h(t) = \sum_{j=1}^J 1_{\{t=H_j\}} K_j$$


โดยที่

J คือ จำนวนวันหยุดทั้งหมดที่กำหนด

$1_{\{t=H_j\}}$ คือ ฟังก์ชันบ่งชี้ที่ โดยจะมีค่าเท่ากับ 1 เมื่อ $t = H_j$ และมีค่าเท่ากับ 0 เมื่อ $t \neq H_j$

K_j คือ ขนาดผลกระทบของวันหยุดที่ j แสดงถึงระดับการเปลี่ยนแปลงของค่าพยากรณ์ในวันหยุด เช่น ค่า K_j มีค่าเป็นบวก หมายถึง วันหยุดนั้นส่งผลให้ยอดขายเพิ่มขึ้น หากค่า K_j มีค่าเป็นลบ หมายถึง วันหยุดนั้นส่งผลให้ยอดขายลดลง

ฟังก์ชันวันหยุด ในตัวแบบ Prophet มีหน้าที่ช่วยให้ตัวแบบสามารถพิจารณาผลกระทบจากวันหยุดหรือเหตุการณ์พิเศษที่อาจมีอิทธิพลต่อยอดขาย เช่น เทศกาลปีใหม่ หรือวันสงกรานต์ โดยตัวแบบจะสร้างตัวแปรแทนวันหยุดเหล่านี้และเรียนรู้ลักษณะการเปลี่ยนแปลงของข้อมูลในช่วงดังกล่าว ส่งผลให้การพยากรณ์มีความแม่นยำและสอดคล้องกับพฤติกรรมจริงของข้อมูลมากยิ่งขึ้น



ภาพที่ 2.6 กราฟตัวอย่างฟังก์ชันวันหยุด

จากภาพที่ 2.6 เป็นกราฟแสดงฟังก์ชันผลกระทบวันหยุดสำหรับข้อมูลที่เก็บเป็นหน่วยรายเดือน ตัวอย่างนี้แสดงวันหยุด 5 รายการโดยแต่ละรายการมีตำแหน่งกึ่งกลาง และขนาดผลกระทบ K_j

4.) ค่าความคลาดเคลื่อน (Error Term)

ค่าความคลาดเคลื่อนเกิดจากปัจจัยที่ตัวแบบไม่สามารถอธิบายได้ เพื่อให้ตัวแบบมีความสมจริง จึงมีการสมมติว่าค่าความคลาดเคลื่อนมีการกระจายแบบปกติ (Normal Distribution) ดังสมการต่อไปนี้

$$\varepsilon_t \sim N(0, \sigma^2)$$

โดยที่

ε_t คือ ค่าความคลาดเคลื่อน ณ เวลา t

$N(0, \sigma^2)$ คือ การแจกแจงแบบปกติ

0 คือ ค่าเฉลี่ยของค่าความคลาดเคลื่อน ซึ่งโดยทั่วไปเท่ากับศูนย์

σ^2 คือ ความแปรปรวนของค่าความคลาดเคลื่อน แสดงถึงระดับความไม่แน่นอนของตัวแบบ

การที่ค่าความคลาดเคลื่อนมีการกระจายแบบปกติและไม่สัมพันธ์กันระหว่างเวลา จะทำให้ผลลัพธ์จากตัวแบบมีความน่าเชื่อถือมากขึ้น และสามารถใช้ในการประมาณค่าพารามิเตอร์ รวมถึงการสร้างช่วงความเชื่อมั่นของการพยากรณ์ได้อย่างถูกต้อง

2.2.1 การประมาณค่าของตัวแบบ Prophet

Prophet ใช้วิธีการประมาณค่าแบบ Maximum a posteriori (MAP) Estimation ซึ่งเป็นวิธีการหาค่าพารามิเตอร์ที่ดีที่สุดโดยพิจารณาจากข้อมูลความน่าจะเป็นสองส่วน คือ ความน่าจะเป็นของข้อมูลที่สังเกตได้ (Likelihood) และการแจกแจงก่อนหน้า (Prior distribution)

ค่าพารามิเตอร์ที่เหมาะสมที่สุด $\hat{\theta}_{MAP}$ สามารถคำนวณได้จากสมการ (Rangan, Fletcher, Goyal, 2009)

$$\hat{\theta}_{MAP} = \arg \max_{\theta} P(\theta | y) = \arg \max_{\theta} [P(y | \theta)P(\theta)]$$

โดยที่

$\hat{\theta}_{MAP}$ คือ ค่าประมาณการของพารามิเตอร์ θ ด้วยวิธีการ MAP

y คือ ข้อมูลที่สังเกตได้ เช่น ข้อมูลยอดขายจริงในแต่ละเดือน

$P(y|\theta)$ คือ ความน่าจะเป็นที่จะได้ข้อมูลที่สังเกตได้เมื่อกำหนดให้พารามิเตอร์ของตัวแบบเป็น θ

$P(\theta)$ คือ การกำหนดความรู้หรือความเชื่อเริ่มต้นเกี่ยวกับค่าคงที่ของพารามิเตอร์ θ ซึ่งในตัวแบบ Prophet จะกำหนดข้อจำกัดที่เน้นค่ากลางสำหรับองค์ประกอบต่าง ๆ เช่น ฤดูกาล ผลกระทบจากวันหยุดและจุดเปลี่ยนแนวโน้ม

θ คือ พารามิเตอร์ทั้งหมดของตัวแบบ ซึ่งประกอบด้วยส่วนประกอบต่าง ๆ ได้แก่ แนวโน้ม ฤดูกาล และผลกระทบจากวันหยุด

การใช้ MAP estimation ช่วยให้ Prophet สามารถควบคุมและลดความซับซ้อนของตัวแบบ โดยเฉพาะเมื่อมีข้อมูลไม่เพียงพอหรือมีค่าผิดปกติ การใช้ข้อจำกัดหรือแนวทางเริ่มต้นจะช่วยให้ค่าพารามิเตอร์ให้กลับมาอยู่ในช่วงที่สมเหตุสมผล ซึ่งช่วยป้องกันปัญหาการจับรูปแบบมากเกินไป (overfitting) ที่เกิดขึ้นเมื่อแบบจำลองเรียนรู้รายละเอียดของข้อมูลมากเกินไป (Taylor, Letham, 2018)

2.2.2 พารามิเตอร์ของตัวแบบ Prophet

ตัวแบบ Prophet มีพารามิเตอร์สำคัญที่ใช้ปรับพฤติกรรมของตัวแบบให้เหมาะสมกับลักษณะข้อมูล ดังนี้

ตาราง 2.1 ค่าพารามิเตอร์ของตัวแบบ Prophet

พารามิเตอร์	ค่าตัวอย่าง	รายละเอียด
growth	“linear”	กำหนดให้ตัวแบบมีแนวโน้มการเติบโตเป็นเส้นตรง
	“logistic”	กำหนดให้ตัวแบบมีแนวโน้มแบบมีขีดจำกัด บน-ล่าง
changepoint_prior_scale	0.001 - 0.5 (ค่าเริ่มต้น 0.05)	ควบคุมความไวของตัวแบบต่อการเปลี่ยนแปลงแนวโน้ม ยิ่งค่า

		สูงแนวโน้มจะเปลี่ยนแปลงได้มากขึ้น ยิ่งค่าต่ำแนวโน้มจะยิ่งเรียบ
seasonality_mode	“additive”	รูปแบบของฤดูกาลแบบบวก ซึ่งผลของฤดูกาลจะมีขนาดเท่ากันตลอด
	“multiplicative”	รูปแบบฤดูกาลแบบคูณกับแนวโน้ม ยิ่งแนวโน้มสูงขึ้นฤดูกาลจะสูงตาม
interval_width	0 – 1 (ค่าเริ่มต้น 0.8)	กำหนดค่าความเชื่อมั่นของค่าพยากรณ์

2.3 ตัวแบบซาริแมกซ์ (Seasonal Autoregressive Integrated Moving Average with exogenous variables - SARIMAX)

ก่อนจะพัฒนาเป็นตัวแบบ SARIMAX นั้น ตัวแบบอนุกรมเวลาได้มีการพัฒนาอย่างต่อเนื่องจาก ARIMA ซึ่งรวมคุณสมบัติของตัวแบบ AutoRegressive (AR) และ MovingAverage (MA) เข้าด้วยกัน ซึ่งสามารถจัดการกับข้อมูลที่มีแนวโน้ม และความไม่คงที่ได้อย่างมีประสิทธิภาพ (Hyndman, Athanasopoulos, 2021) ภายหลังได้มีการพัฒนาเป็นตัวแบบ SARIMA เพื่อเพิ่มความสามารถในการจัดการข้อมูลที่มีลักษณะฤดูกาลโดยเพิ่มองค์ประกอบเชิงฤดูกาลเข้าไปในโครงสร้างของ ARIMA และในที่สุดพัฒนาเป็น SARIMAX โดยเพิ่มตัวแปรภายนอกเข้ามาในตัวแบบ เพื่อให้สามารถอธิบายปัจจัยภายนอกที่ส่งผลต่อข้อมูลได้อย่างแม่นยำยิ่งขึ้น (Alharbi, Csala, 2022)

2.3.1 ตัวแบบอาร์ิมา (AutoRegressive Integrated Moving Average - ARIMA)

ตัวแบบ ARIMA หรือ AutoRegressive Integrated Moving Average เป็นหนึ่งในตัวแบบการพยากรณ์อนุกรมเวลาที่มีความนิยมและใช้งานอย่างแพร่หลาย เนื่องจากสามารถจัดการกับข้อมูลที่มีแนวโน้ม และความไม่คงที่ได้ดี โดยแนวคิดหลักของตัวแบบนี้มาจากการรวมกันของ 3 ส่วนสำคัญ ได้แก่

1.) AutoRegressive (AR)

ส่วนนี้แสดงถึงความสัมพันธ์ระหว่างค่าของตัวแปรในปัจจุบันกับค่าของตัวแปรในอดีตในเชิงเชิงเส้น เช่น การทำนายยอดขายเดือนนี้ขึ้นอยู่กับยอดขายในเดือนที่ผ่านมา ซึ่งสามารถเขียนอยู่ในรูปสมการได้ดังนี้

$$Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + \varepsilon_t$$

โดยที่

Y_t คือ ค่าของตัวแปรในเวลา t

c คือ ค่าคงที่

$\phi_1, \phi_2, \dots, \phi_p$ คือ ค่าสัมประสิทธิ์ของตัวแบบ

ε_t คือ ค่าความคลาดเคลื่อนสุ่ม ณ เวลา t

2.) Integrated (I)

ข้อมูลที่ไม่คงที่มักทำให้การวิเคราะห์เชิงสถิติหรือการพยากรณ์เชิงเวลาเป็นไปได้ยาก เนื่องจากค่าทางสถิติของข้อมูล เช่น ค่าเฉลี่ย ความแปรปรวน เปลี่ยนแปลงตามเวลา ดังนั้นการมีข้อมูลที่มีความคงที่จะช่วยให้สามารถระบุรูปแบบและความสัมพันธ์เชิงเวลาได้ชัดเจน ทำให้การวิเคราะห์และตีความผลมีความแม่นยำมากขึ้น ซึ่งตัวแบบ ARIMA ต้องการข้อมูลที่คงที่ เพราะตัวแบบนี้อาศัย “ความสัมพันธ์ของค่าในอดีตกับอนาคต” และจะทำงานได้ดีเมื่อโครงสร้างของข้อมูลไม่เปลี่ยนไปตามเวลา ดังนั้น ก่อนนำข้อมูลไปใช้กับตัวแบบ ARIMA จึงมักต้องผ่านกระบวนการหาผลต่าง (Differencing) เพื่อปรับให้ค่าเฉลี่ยและความแปรปรวนไม่ขึ้นกับเวลา

กระบวนการ Differencing คือ การหาค่าความต่างระหว่างข้อมูลในช่วงเวลาปัจจุบันกับช่วงเวลาก่อนหน้า ตัวอย่างเช่น

- $d = 1$:

$$Y'_t = Y_t - Y_{t-1}$$

- $d = 2$:

$$Y''_t = (Y_t - Y_{t-1}) - (Y_{t-1} - Y_{t-2})$$

โดยทั่วไป ค่า d มักมีค่าตั้งแต่ 0-2 ทั้งนี้ขึ้นอยู่กับลักษณะของข้อมูล หากหลังจากทำการ Differencing ข้อมูลค่าเฉลี่ยและความแปรปรวนไม่เปลี่ยนแปลงตามเวลา แสดงว่าข้อมูลมีความคงที่พร้อมสำหรับการนำไปสร้างตัวแบบ ARIMA ต่อไป

3.) Moving Average (MA)

ตัวแบบ MA เป็นตัวแบบที่อธิบายค่าปัจจุบันของอนุกรมเวลาโดยพิจารณาความสัมพันธ์ระหว่างค่าความคลาดเคลื่อนในอดีต ซึ่งช่วยลดความผันผวนของข้อมูลและเพิ่มความแม่นยำในการพยากรณ์

$$Y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q}$$

โดยที่

ε_t คือ ค่าความคลาดเคลื่อนสุ่ม ณ เวลา t

μ คือ ค่าเฉลี่ยของข้อมูล

$\theta_1, \theta_2, \dots, \theta_q$ คือ ค่าสัมประสิทธิ์ของ MA

เมื่อนำ AR, I และ MA มารวมกัน จะได้ตัวแบบ ARIMA(p, d, q) โดยสมการทั่วไปเขียนได้ว่า

$$Y_t = c + \phi_1 Y_{t-1}^{(d)} + \dots + \phi_p Y_{t-p}^{(d)} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$

โดยที่

p คือ ลำดับของส่วน AR

d คือ ระดับของการทำให้ข้อมูลนิ่ง

q คือ ลำดับของส่วน MA

ตัวแบบ ARIMA จึงสามารถจัดการกับข้อมูลที่มีแนวโน้มได้ดี แต่หากข้อมูลมีฤดูกาล จำเป็นต้องขยายไปใช้ตัวแบบ SARIMA เพื่อให้ครอบคลุมรูปแบบซ้ำตามฤดูกาล

2.3.2 ตัวแบบซาริมา (Seasonal Autoregressive Integrated Moving Average - SARIMA)

ตัวแบบ SARIMA คือ การพัฒนาต่อยอดจากตัวแบบ ARIMA เพื่อให้สามารถจัดการกับข้อมูลอนุกรมเวลาที่มีรูปแบบ ฤดูกาล ได้อย่างมีประสิทธิภาพมากขึ้น โดยการเพิ่มพารามิเตอร์ของส่วนฤดูกาลเข้าไปในตัวแบบเดิม ดังนั้น ตัวแบบ SARIMA จึงเหมาะสมอย่างยิ่งสำหรับการพยากรณ์ข้อมูลที่มีการเปลี่ยนแปลงซ้ำ ๆ เป็นรอบตามช่วงเวลาที่น่าสนใจ เช่น ยอดขายรายเดือนที่มีรูปแบบขึ้นลงคล้ายกันในแต่ละปี ข้อมูลอุณหภูมิที่มีรูปแบบตามฤดูกาลต่าง ๆ (เตชินท์ มณีศร, 2563)

ตัวแบบ SARIMA ประกอบด้วยพารามิเตอร์หลัก 2 ชุด ได้แก่ พารามิเตอร์แบบไม่เป็นฤดูกาล และพารามิเตอร์แบบฤดูกาล ซึ่งสามารถเขียนในรูปแบบทั่วไปได้ดังนี้

$$SARIMA(p, d, q)(P, D, Q)_s$$

และสมการของตัวแบบ SARIMA สามารถแสดงในรูปแบบขยายได้ดังนี้

$$ARIMA(p, d, q) + \Phi_1 Y_{t-s}^{(D)} + \dots + \Phi_p Y_{t-ps}^{(D)} + \Theta_1 \varepsilon_{t-s} + \dots + \Theta_Q \varepsilon_{t-Qs}$$

โดยที่

P (SAR - Seasonal Autoregressive) คือ จำนวนลำดับของ AR ในองค์ประกอบตามฤดูกาล

D (SI - Seasonal Integrated) คือ จำนวนครั้งของการทำ differencing ในองค์ประกอบตามฤดูกาล

Q (SMA - Seasonal Moving Average) คือ จำนวนลำดับของ MA ใน องค์ประกอบตามฤดูกาล

s (Seasonal period) คือ ความยาวของรอบฤดูกาล เช่น $s = 12$ สำหรับข้อมูลรายเดือนที่มีฤดูกาลรายปี หรือ $s = 4$ สำหรับข้อมูลรายไตรมาส

ดังนั้นตัวแบบ SARIMA จึงสามารถจัดการกับข้อมูลที่มีทั้งแนวโน้มและฤดูกาลได้ดีกว่า ARIMA

2.3.3 ตัวแบบซารีแมกซ์ (Seasonal Autoregressive Integrated Moving Average with exogenous variables - SARIMAX)

ตัวแบบ SARIMAX เป็นการต่อยอดจากตัวแบบ SARIMA โดยถูกออกแบบมาเพื่อแก้ไขข้อจำกัดที่สำคัญของตัวแบบอนุกรมเวลาทั่วไป คือ การที่ตัวแบบเหล่านั้นมักจะพิจารณาเฉพาะปัจจัยภายในของข้อมูล (เช่น แนวโน้มและฤดูกาล) แต่ละเลยอิทธิพลจากปัจจัยภายนอกที่ส่งผลกระทบต่อข้อมูลอนุกรมเวลาในโลกความเป็นจริง

ตัวแบบ SARIMAX ทำงานโดยเพิ่มตัวแปรภายนอก $X(t)$ เข้าไปในสมการของตัวแบบ SARIMA เพื่อช่วยอธิบายความผันแปรของข้อมูลได้ครอบคลุมยิ่งขึ้น ตัวแปรภายนอกเหล่านี้แม้ไม่ใช่ส่วนหนึ่งของอนุกรมเวลาหลัก แต่มีอิทธิพลต่อการเปลี่ยนแปลงของข้อมูล เช่น สภาพอากาศ ฤดูกาล หรือกิจกรรมทางการตลาด การผนวกปัจจัยภายนอกดังกล่าวช่วยให้ตัวแบบสะท้อนพฤติกรรมของข้อมูลได้ใกล้เคียงความเป็นจริงและเพิ่มความแม่นยำในการพยากรณ์มากขึ้น

สมการทั่วไปของตัวแบบ SARIMAX จึงถูกขยายเป็น

$$SARIMA(p,d,q)(P,D,Q)_s + \tilde{\beta}^T \tilde{X}(t)$$

โดยที่

$\tilde{X}(t)$ คือ เวกเตอร์ของตัวแปรภายนอกที่ใช้เป็นตัวแปรอิสระในการช่วยอธิบายการเปลี่ยนแปลงของตัวแปรตาม

$\tilde{\beta}$ คือ เวกเตอร์ของค่าสัมประสิทธิ์ที่แสดงผลกระทบของแต่ละตัวแปรภายนอก

$$\text{โดย } \tilde{X}(t) = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_k \end{bmatrix} \text{ และ } \tilde{\beta}(t) = \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{bmatrix}$$

โดยสรุป ตัวแบบ SARIMAX เป็นการขยายของตัวแบบ ARIMA ที่เพิ่มความสามารถในการรองรับฤดูกาลและตัวแปรภายนอก เพื่อให้สามารถจับรูปแบบของข้อมูลที่ซับซ้อนได้ดียิ่งขึ้น

2.3.4 พารามิเตอร์ของตัวแบบ SARIMAX

ตัวแบบ SARIMAX มีพารามิเตอร์สำคัญที่ใช้ปรับพฤติกรรมของตัวแบบให้เหมาะสมกับลักษณะข้อมูล ดังนี้

ตาราง 2.2 ค่าพารามิเตอร์ของตัวแบบ SARIMAX

พารามิเตอร์	ค่าตัวอย่าง	รายละเอียด
endog	y_train	ตัวแปรตาม สำหรับการเรียนรู้ของตัวแบบ (ยอดขายรายเดือน)
exog	X_train	ตัวแปรภายนอก
order	(p,d,q)	โครงสร้างของ ARIMA โดยกำหนดค่า p = ลำดับ AR , d = จำนวน differencing, q = ลำดับ MA
seasonal_order	(P,D,Q,s)	โครงสร้างของส่วนฤดูกาล โดยกำหนดค่า $P = SAR$, $D =$

		Seasonal differencing, $Q = SMA$, $s =$ ความยาวฤดูกาล
enforce_stationarity	True/False	True จะบังคับให้พารามิเตอร์ของตัวแบบอยู่ในช่วงที่ข้อมูลคงที่ False จะอนุญาตให้ตัวแบบมีพารามิเตอร์ที่ทำให้ข้อมูลไม่คงที่
enforce_invertibility	True/False	True บังคับให้ตัวแบบเรียนรู้ข้อผิดพลาดในอดีต False ไม่บังคับให้ตัวแบบเรียนรู้ข้อผิดพลาดในอดีต

ในการวิจัยนี้ได้ใช้วิธี Auto ARIMA เพื่อช่วยเลือกค่าพารามิเตอร์ที่เหมาะสมที่สุดโดยอัตโนมัติ ได้แก่ p, d, q, P, D, Q, s ซึ่งเป็นค่าที่กำหนดโครงสร้างของตัวแบบ โดยประเมินจากเกณฑ์ Akaike Information Criterion (AIC) เพื่อให้ได้ตัวแบบที่ให้ผลการพยากรณ์อย่างมีประสิทธิภาพและมีความแม่นยำสูงสุด

2.3.5 Auto ARIMA และเกณฑ์การเลือกตัวแบบด้วยค่า AIC

Auto ARIMA (Automatic ARIMA) เป็นวิธีการอัตโนมัติที่ช่วยในการเลือกพารามิเตอร์ของตัวแบบ ARIMA ให้เหมาะสมที่สุด โดยไม่จำเป็นต้องกำหนดค่าพารามิเตอร์ด้วยตนเอง ซึ่งช่วยลดระยะเวลาในการสร้างตัวแบบและเพิ่มความแม่นยำของผลลัพธ์ (Hyndman, Khandakar, 2008) นอกจากนี้กระบวนการนี้ยังสามารถประยุกต์ใช้ร่วมกับตัวแบบ SARIMAX เพื่อเพิ่มประสิทธิภาพในการพยากรณ์ข้อมูลที่มีปัจจัยภายนอก

ค่า AIC เป็นเกณฑ์ทางสถิติที่ใช้วัดความเหมาะสมของตัวแบบ โดยพิจารณาจากสมดุลระหว่างความซับซ้อนของตัวแบบและ ความสามารถในการอธิบายข้อมูล คำนวณได้จากสูตร

$$AIC = 2k - 2 \ln(L)$$

โดยที่

k คือ จำนวนพารามิเตอร์ในตัวแบบ

L คือ ค่าความน่าจะเป็นสูงสุด (maximum likelihood) ของตัวแบบ ซึ่งหมายถึงค่าความน่าจะเป็นที่ทำให้ตัวแบบสามารถอธิบายข้อมูลที่สังเกตได้ดีที่สุด

หลักการของ AIC คือ ใช้ประเมินความเหมาะสมของตัวแบบ โดยค่าที่ต่ำกว่าจะบ่งชี้ว่าตัวแบบสามารถอธิบายข้อมูลได้อย่างเหมาะสมโดยไม่ซับซ้อนเกินไป ดังนั้น การเลือกตัวแบบที่มีค่า AIC ต่ำสุดจึงเป็นวิธีที่นิยมใช้ในการคัดเลือกตัวแบบพยากรณ์ที่มีประสิทธิภาพ

2.4 ตัวชี้วัดความแม่นยำของตัวแบบ

ตัวชี้วัดความคลาดเคลื่อนทั่วไปในการประเมินประสิทธิภาพของตัวแบบการพยากรณ์ที่ (Alharbi, Csala, 2022) เสนอไว้ เพื่อเปรียบเทียบความแม่นยำของผลลัพธ์จากตัวแบบพยากรณ์ ได้แก่ โดยกำหนดตัวแปรดังนี้

n คือ จำนวนข้อมูลทั้งหมด

y_i คือ ค่าของข้อมูลจริงลำดับที่ i

$\hat{y}_i$ คือ ค่าพยากรณ์ลำดับที่ i

1.) ค่าความคลาดเคลื่อนเฉลี่ยแบบสัมบูรณ์ (Mean Absolute Error - MAE) ค่านี้จะบอกค่าเฉลี่ยของความแตกต่างระหว่างข้อมูลที่พยากรณ์กับข้อมูลจริง โดยไม่คำนึงถึงทิศทางของข้อผิดพลาด MAE ที่มีค่าต่ำแสดงว่าตัวแบบมีความแม่นยำสูง โดยมีสูตรคำนวณดังนี้

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

2.) ค่ารากของค่าคลาดเคลื่อนกำลังสองเฉลี่ย (Root Mean Squared Error - RMSE) เป็นตัวชี้วัดความแม่นยำของแบบจำลองที่ให้ความสำคัญกับข้อผิดพลาดที่มีขนาดใหญ่ เนื่องจากระดับการคำนวณจะทำการยกกำลังสองของค่าความคลาดเคลื่อนก่อนนำมาหาค่าเฉลี่ย ส่งผลให้ข้อผิดพลาดที่มีค่ามากส่งผลกระทบต่อค่า RMSE มากกว่าค่า MAE โดยมีสูตรคำนวณดังนี้

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

3.) ค่าร้อยละความคลาดเคลื่อนสัมบูรณ์เฉลี่ย (Mean Absolute Percentage Error - MAPE) เป็นตัวชี้วัดที่ใช้ประเมินความแม่นยำของแบบจำลองการพยากรณ์ โดยคำนวณจากร้อยละของค่าความคลาดเคลื่อนสัมบูรณ์ระหว่างค่าจริงเทียบกับค่าที่ตัวแบบพยากรณ์ได้ในแต่ละช่วงเวลา จากนั้นนำค่าความคลาดเคลื่อนดังกล่าวมาหาค่าเฉลี่ยทั้งหมด ค่าของ MAPE มักแสดงเป็นร้อยละเพื่อให้ง่ายต่อการตีความ

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100$$

ค่าชี้วัดเหล่านี้ช่วยให้สามารถประเมินและเปรียบเทียบความแม่นยำของตัวแบบแต่ละแบบได้อย่างมีระบบ และช่วยในการตัดสินใจเลือกตัวแบบที่เหมาะสมที่สุดสำหรับการพยากรณ์ยอดขายในบริบทของข้อมูลที่กำหนด

บทที่ 3 วิธีดำเนินการวิจัย

บทนี้นำเสนอขั้นตอนการดำเนินโครงการพยากรณ์ยอดขาย โดยประกอบด้วยกระบวนการสำคัญ ได้แก่ การเลือกแหล่งข้อมูล การเตรียมข้อมูลให้พร้อมสำหรับการวิเคราะห์ การเลือกตัวแบบทางสถิติที่เหมาะสม การฝึกและทดสอบตัวแบบ ตลอดจนการประเมินประสิทธิภาพของตัวแบบการพยากรณ์ เพื่อให้ได้ผลการคาดการณ์ที่มีความถูกต้องและน่าเชื่อถือ รายละเอียดของแต่ละขั้นตอนแสดงดังต่อไปนี้

3.1 เครื่องมือที่ใช้ในการดำเนินงาน

- เครื่องคอมพิวเตอร์โน้ตบุ๊ก ASUS รุ่น LAPTOP-V0LUV9AA
ซึ่งประกอบด้วยหน่วยประมวลผลกลาง (CPU) แบบ AMD Ryzen 7 5800HS with Radeon Graphics ความเร็ว 3.20 GHz
หน่วยความจำหลัก (RAM) ขนาด 8 กิกะไบต์ (GB) และสถาปัตยกรรมระบบแบบ 64-bit
โดยใช้ระบบปฏิบัติการ Windows 11 Home Single Language เวอร์ชัน 25H2 (OS Build 26200.6901)
- Python (เวอร์ชัน 3.10.9.final.0)
- ไลบรารี: pandas, numpy, matplotlib.pyplot, seasonal_decompose, Prophet, auto_arima, SARIMAX, mean_squared_error, mean_absolute_error

3.2 แหล่งข้อมูลที่ใช้ในการวิจัย

ข้อมูลยอดขายจากบริษัท ABC จำนวน 3 ตัวแปร โดยมีจำนวนทั้งหมด 4,500 รายการ ครอบคลุมช่วงเวลาตั้งแต่วันที่ 1 มกราคม ค.ศ. 2021 ถึงวันที่ 31 ธันวาคม ค.ศ. 2024 ประกอบด้วย

ตาราง 3.1 ข้อมูลยอดขายจากบริษัท ABC

ลำดับ	ตัวแปร	ความหมาย
1	doc_id	รหัสใบเสร็จ
2	date	วันที่ (วัน/เดือน/ปี)
3	grandtotal	ยอดขายสุทธิ

3.3 การจัดเตรียมข้อมูล

ขั้นตอนนี้เป็นกระบวนการสำคัญที่จะทำให้ข้อมูลพร้อมสำหรับการสร้างตัวแบบ เนื่องจากข้อมูลยอดขายที่ใช้ในการวิเคราะห์มีการจัดเก็บในรูปแบบรายวัน ซึ่งมีความผันผวนสูงจากปัจจัยด้าน

ฤดูกาล วันหยุด หรือกิจกรรมทางการตลาดต่าง ๆ ที่ส่งผลให้ยอดขายแต่ละวันแตกต่างกันอย่างมาก จึงได้ดำเนินการปรับโครงสร้างและเตรียมข้อมูลใหม่ให้เหมาะสมต่อการนำไปใช้ในการสร้างตัวแบบการพยากรณ์ โดยมีกระบวนการทำต่อไปนี้

3.3.1 การตรวจสอบและลบข้อมูลซ้ำ

จากการตรวจสอบพบว่า ภายในแต่ละ doc_id มีค่าของตัวแปร grandtotal ที่ซ้ำกันหลายแถว ข้อมูลดังกล่าวจัดเป็นรายการซ้ำซ้อน ซึ่งไม่มีประโยชน์ต่อการวิเคราะห์ อีกทั้งยังอาจส่งผลให้เกิดความคลาดเคลื่อนในผลการพยากรณ์ได้

ดังนั้น ผู้จัดทำจึงได้ทำการคัดเลือกเฉพาะข้อมูลที่มี doc_id ไม่ซ้ำกัน เพื่อให้แต่ละแถวแทนรายการขายจริงเพียงครั้งเดียว หลังจากดำเนินการคัดกรองข้อมูลซ้ำออกแล้ว พบว่าจำนวนข้อมูลทั้งหมดลดลงจาก 4,500 รายการ เหลือ 2,679 รายการ ซึ่งช่วยให้ข้อมูลมีความถูกต้องมากขึ้น และสามารถนำไปใช้ในการวิเคราะห์และพยากรณ์ยอดขายได้อย่างมีประสิทธิภาพ

3.3.2 การจัดรูปแบบข้อมูลวันที่และเวลา (Date and Time Formatting)

เดิมข้อมูลวันที่ในชุดข้อมูลถูกจัดเก็บในรูปแบบ วัน/เดือน/ปี (DD/MM/YYYY) ซึ่งไม่สอดคล้องกับรูปแบบมาตรฐานที่ตัวแบบการพยากรณ์ต้องการ จึงได้ทำการปรับรูปแบบคอลัมน์วันที่ให้อยู่ในมาตรฐาน YYYY-MM-DD เพื่อให้สามารถนำไปใช้กับตัวแบบได้อย่างถูกต้อง

3.3.3 การตรวจสอบและจัดการข้อมูลเชิงสถิติ

ก่อนดำเนินการปรับโครงสร้างข้อมูล ผู้จัดทำได้ทำการตรวจสอบลักษณะเชิงสถิติเบื้องต้นของข้อมูลยอดขาย เพื่อทำความเข้าใจการกระจายตัวและระดับความแปรปรวนของข้อมูลดิบ โดยพิจารณาค่าทางสถิติพื้นฐาน ได้แก่ จำนวนข้อมูลทั้งหมด (Count) ค่าเฉลี่ย (Mean) ค่าต่ำสุด (Minimum) ค่าสูงสุด (Maximum) และส่วนเบี่ยงเบนมาตรฐาน (Standard Deviation) ดังตาราง

3.2

ตาราง 3.2 ข้อมูลเชิงสถิติของยอดขาย

ค่าสถิติ	ยอดขาย (บาท)
จำนวนข้อมูลทั้งหมด	2,679
ค่าเฉลี่ย	41,544.394
ค่าต่ำสุด	96.30
ค่าเบี่ยงเบนมาตรฐาน	193,179.129

ค่าสูงสุด	4,950,000.00
-----------	--------------

จากผลการตรวจสอบพบว่า ข้อมูลยอดขายมีจำนวนทั้งสิ้น 2,679 รายการ โดยมียอดขายต่ำสุดอยู่ที่ 96.30 บาท และสูงสุดประมาณ 4,950,000 บาท สะท้อนให้เห็นถึงความแตกต่างของยอดขายในแต่ละวันค่อนข้างมาก อีกทั้งยังมีค่าเบี่ยงเบนมาตรฐานสูง แสดงถึงความผันผวนของข้อมูลสูง ดังนั้นจึงจำเป็นต้องดำเนินการจัดกลุ่มและปรับโครงสร้างข้อมูล เพื่อให้เหมาะสมต่อการนำไปใช้ในการสร้างตัวแบบพยากรณ์ในขั้นตอนถัดไป

เพื่อเสริมความถูกต้องของข้อมูล ผู้จัดทำได้ดำเนินการตรวจสอบค่าผิดปกติ โดยใช้เกณฑ์เปอร์เซ็นไทล์ที่ 95 เป็นจุดตัดในการคัดกรองข้อมูลเฉพาะที่อยู่ในช่วงค่าปกติ และนำค่าที่มีมูลค่าสูงเกินขอบเขตดังกล่าวออก การดำเนินการนี้ช่วยลดอิทธิพลของค่าผิดปกติที่อาจส่งผลให้ตัวแบบเรียนรู้แนวโน้มของข้อมูลผิดพลาด

นอกจากนี้ ผู้จัดทำยังได้ทำการตรวจสอบค่าทางสถิติเบื้องต้นอีกครั้งหลังการตัดข้อมูล พบว่า ค่าเฉลี่ยและส่วนเบี่ยงเบนมาตรฐานของยอดขายมีค่าลดลงเมื่อเปรียบเทียบกับข้อมูลต้นฉบับรายวัน ซึ่งสะท้อนให้เห็นว่าการนำค่าผิดปกติออกช่วยลดความผันผวนของข้อมูล ทำให้ชุดข้อมูลมีความเสถียรและสอดคล้องกับรูปแบบเชิงธุรกิจมากยิ่งขึ้น ดังตาราง 3.3

การดำเนินการที่กล่าวไปนั้นมีความสำคัญอย่างยิ่งต่อการสร้างตัวแบบพยากรณ์ เนื่องจากตัวแบบเชิงอนุกรมเวลาอ่อนไหวต่อค่าที่ผิดปกติ หากปล่อยให้ค่าผิดปกติเข้าไปโดยไม่ปรับจะส่งผลให้การประมาณค่าพารามิเตอร์และการพยากรณ์มีความคลาดเคลื่อนสูง ซึ่งอาจลดความแม่นยำและความน่าเชื่อถือของผลลัพธ์ที่ได้

ตาราง 3.3 ข้อมูลเชิงสถิติหลังตัดค่าผิดปกติ

ค่าสถิติ	ยอดขาย (บาท)
จำนวนข้อมูลทั้งหมด	2,545
ค่าเฉลี่ย	15,302.482
ค่าต่ำสุด	96.30
ค่าเบี่ยงเบนมาตรฐาน	22,454.302
ค่าสูงสุด	148,409.00

หลังจากการตัดค่าผิดปกติ จำนวนข้อมูลลดลงจาก 2,679 รายการ เหลือ 2,545 รายการ โดยค่าความแปรปรวนของข้อมูลลดลงอย่างชัดเจน ค่าเบี่ยงเบนมาตรฐานลดลงเหลือ 22,454.302 บาท และค่าสูงสุด ลดลงจาก 4,950,000 บาท เหลือเพียง 148,409 บาท ขณะที่ค่าเฉลี่ยลดลงเหลือ 15,302.482 บาท แสดงให้เห็นว่าข้อมูลหลังการปรับมีความสมดุลและสอดคล้องกับสภาพจริงของยอดขายมากขึ้น ซึ่งเหมาะต่อการนำไปใช้ในการสร้างตัวแบบพยากรณ์ยอดขายในขั้นตอนถัดไป

3.3.4 การจัดกลุ่มข้อมูล (Data Aggregation)

ข้อมูลยอดขายดิบที่เก็บรวบรวมได้มีลักษณะเป็นรายวัน ซึ่งมีจำนวนข้อมูลค่อนข้างมากและมีความผันผวนสูง จึงได้ดำเนินการจัดกลุ่มข้อมูลให้อยู่ในระดับรายเดือน โดยการรวมยอดขายของแต่ละวันภายในเดือนเดียวกัน เพื่อให้เหมาะต่อการสร้างตัวแบบการพยากรณ์ ผลลัพธ์หลังการจัดกลุ่มมีจำนวนข้อมูล 48 รายการ

ตาราง 3.4 ข้อมูลหลังจากการจัดกลุ่มข้อมูล

ลำดับ	ตัวแปร	ความหมาย
1	date	วันที่ (เดือน/ปี)
2	grandtotal	ยอดขายสุทธิ

หลังจากจัดกลุ่มข้อมูลให้อยู่ในระดับรายเดือนแล้ว ได้ทำการตรวจสอบค่าทางสถิติเชิงพรรณนาอีกครั้ง เพื่อประเมินความแตกต่างของการกระจายข้อมูลก่อนและหลังการจัดกลุ่ม ดังตาราง 3.5


ตาราง 3.5 ข้อมูลเชิงสถิติหลังการจัดกลุ่มข้อมูล

ค่าสถิติ	ยอดขาย (บาท)
จำนวนข้อมูลทั้งหมด	48
ค่าเฉลี่ย	811,350.37
ค่าต่ำสุด	259,448.16
ค่าเบี่ยงเบนมาตรฐาน	321,963.81
ค่าสูงสุด	1,712,289.11

จาก ตาราง 3.5 พบว่าการจัดกลุ่มข้อมูลเป็นรายเดือนช่วยลดความผันผวนของข้อมูลย่อยในแต่ละวัน แต่ขณะเดียวกันแสดงให้เห็นถึงความแตกต่างของยอดขายระหว่างเดือนที่ชัดเจนมากขึ้น อันเป็นลักษณะที่เหมาะสมต่อการนำไปสร้างตัวแบบพยากรณ์ในขั้นตอนถัดไป


3.3.5 การตรวจสอบรูปแบบของอนุกรมเวลา (Determination of Time Series Model Type)

ในการวิเคราะห์อนุกรมเวลา ก่อนการสร้างตัวแบบพยากรณ์ ผู้จัดทำได้ทำการตรวจสอบลักษณะของข้อมูลยอดขายรายเดือน เพื่อพิจารณาความเหมาะสมของตัวแบบแบบผลบวก และตัวแบบแบบผลคูณ โดยใช้วิธีการแยกองค์ประกอบของอนุกรมเวลา ซึ่งแบ่งข้อมูลออกเป็น 3 ส่วน ได้แก่ ส่วนแนวโน้ม ส่วนฤดูกาล และส่วนที่เหลือ การวิเคราะห์นี้ช่วยให้สามารถระบุได้ว่าความผันผวนของข้อมูลมีลักษณะคงที่หรือเพิ่มขึ้นตามระดับของข้อมูลหลัก ซึ่งเป็นปัจจัยสำคัญในการเลือกประเภทของตัวแบบที่เหมาะสมสำหรับการพยากรณ์ในขั้นตอนต่อไป



ภาพที่ 3.1 กราฟองค์ประกอบของอนุกรมเวลาแบบผลบวก

จากภาพที่ 3.1 เป็นกราฟแสดงการแยกองค์ประกอบของข้อมูลยอดขายรายเดือนออกเป็น ส่วน Trend Seasonality และ Residual โดยใช้ตัวแบบแบบผลบวก พบว่าค่าความผันผวนของฤดูกาลมีขนาดคงที่ตลอดช่วงเวลา และไม่เปลี่ยนแปลงตามระดับของยอดขาย



ภาพที่ 3.2 กราฟองค์ประกอบของอนุกรมเวลาแบบผลคูณ

จากภาพที่ 3.2 เป็นกราฟแสดงการแยกองค์ประกอบของข้อมูลยอดขายรายเดือนออกเป็น ส่วน Trend Seasonality และ Residual โดยใช้ตัวแบบเชิงคูณ พบว่าขนาดของฤดูกาลมีการเปลี่ยนแปลงสัมพันธ์กับระดับของยอดขาย กล่าวคือ เมื่อยอดขายเพิ่มขึ้น ความผันผวนของฤดูกาลก็เพิ่มขึ้นด้วย

จากผลการแยกองค์ประกอบของอนุกรมเวลา ทั้งในรูปแบบผลบวก และผลคูณ พบว่าข้อมูลยอดขายรายเดือนมีความผันผวนที่เพิ่มขึ้นตามระดับของยอดขายในแต่ละช่วงเวลา ซึ่งเป็นลักษณะเฉพาะของอนุกรมเวลาแบบเชิงคูณ ผลการวิเคราะห์ส่วน Residual ของตัวแบบเชิงคูณมีการกระจายตัวที่สม่ำเสมอและไม่มีรูปแบบหลงเหลือ ในขณะที่ตัวแบบเชิงบวกแสดงให้เห็นความแปรปรวนที่ไม่คงที่ ดังนั้น จึงสรุปได้ว่าข้อมูลชุดนี้มีลักษณะเป็น อนุกรมเวลาแบบผลคูณ ซึ่งสะท้อนให้เห็นว่าขนาดของฤดูกาลมีการเปลี่ยนแปลงตามระดับของข้อมูลในแนวโน้มหลัก

3.3.6 การสร้างและการแปลงตัวแปรคุณลักษณะ (Feature Creation and Transformation)

เพื่อเพิ่มประสิทธิภาพของตัวแบบในการพยากรณ์ยอดขายเชิงเวลา ได้ดำเนินการสร้างและวิศวกรรมคุณลักษณะ (Feature Engineering) จากข้อมูล เช่น การสร้างตัวแปรแนวโน้มและฤดูกาล

รวมถึงการรวมตัวแปรภายนอกที่มีอิทธิพลต่อยอดขาย โดยมีวัตถุประสงค์เพื่อให้ตัวแบบสามารถเรียนรู้ลักษณะเชิงลึกของข้อมูลได้ดีขึ้น โดยมีรายละเอียดดังนี้

1.) ตัวแปรฤดูกาล (seasonal)

การแยกองค์ประกอบของฤดูกาลจากข้อมูลยอดขายด้วยเทคนิค Seasonal Decomposition จากไลบรารี Statsmodels ซึ่งเป็นวิธีการแยกข้อมูลอนุกรมเวลาออกเป็น ส่วนแนวโน้ม ฤดูกาล และส่วนความคลาดเคลื่อน เพื่อวิเคราะห์รูปแบบการเปลี่ยนแปลงตามช่วงเวลา จากนั้นได้นำค่าฤดูกาล (Seasonal Component) ที่ได้มาสร้างเป็นคอลัมน์ใหม่ ในชุดข้อมูล เพื่อใช้เป็นตัวแปรภายนอก เพิ่มความสามารถของตัวแบบในการเรียนรู้รูปแบบฤดูกาลที่เกิดขึ้นอย่างมีประสิทธิภาพมากขึ้น

2.) ตัวแปรจำนวนการขายรายเดือน (sales_count)

การนับจำนวนการขายในแต่ละเดือน และสร้างเป็นตัวแปรภายนอก เพื่อใช้เป็นตัวแทนของระดับกิจกรรมทางการขาย ซึ่งช่วยให้ตัวแบบสามารถอธิบายความผันผวนของยอดขาย และเรียนรู้แนวโน้มการเปลี่ยนแปลงเชิงพฤติกรรมของผู้บริโภคได้แม่นยำยิ่งขึ้น

3.) ตัวแปรเหตุการณ์พิเศษ (holidays)

การตรวจสอบข้อมูลยอดขายเพื่อระบุช่วงเวลาที่มียอดขายสูงผิดปกติ โดยใช้เกณฑ์เปอร์เซ็นต์ไทล์ที่ 99 (99th Percentile) เป็นเกณฑ์ในการคัดแยกค่าที่สูงกว่าระดับปกติ จากนั้นได้กำหนดช่วงเวลาดังกล่าวให้เป็น เหตุการณ์พิเศษ และสร้างเป็น ตัวแปรภายนอก เพื่อช่วยให้ตัวแบบสามารถเรียนรู้และอธิบายผลกระทบของโปรโมชั่นหรือกิจกรรมทางการตลาดที่ทำให้ยอดขายเพิ่มขึ้นได้อย่างเหมาะสม

การสร้างและแปลงตัวแปรคุณลักษณะดังกล่าวมีวัตถุประสงค์เพื่อเพิ่มความสามารถของตัวแบบในการอธิบายความผันผวนของยอดขายและรูปแบบตามฤดูกาล รวมทั้งปัจจัยภายนอก ทำให้การพยากรณ์มีความแม่นยำและสอดคล้องกับข้อมูลจริงมากยิ่งขึ้น

3.3.7 การแบ่งชุดข้อมูล (Data Partitioning)

ชุดข้อมูลอนุกรมเวลาทั้งหมดถูกแบ่งออกเป็นสองส่วนตามลำดับเวลาเพื่อวัตถุประสงค์ในการฝึกและประเมินประสิทธิภาพของตัวแบบ โดยใช้วิธี การแบ่งข้อมูลออกเป็นชุดฝึกและชุดทดสอบ ดังนี้

ชุดข้อมูลฝึก: ใช้ข้อมูลตั้งแต่เดือน มกราคม ค.ศ. 2021 ถึงเดือน ธันวาคม ค.ศ. 2023 โดยใช้ข้อมูลทั้งสิ้น 36 รายการเพื่อหาค่าพารามิเตอร์ที่เหมาะสมที่สุดของตัวแบบ

ชุดข้อมูลทดสอบ: ใช้ข้อมูลตั้งแต่เดือน มกราคม ค.ศ. 2024 ถึงเดือน ธันวาคม ค.ศ. 2024 มีทั้งสิ้น 12 รายการซึ่งเป็นข้อมูลที่ตัวแบบไม่เคยเห็นมาก่อน เพื่อใช้ในการวัดความแม่นยำของการพยากรณ์

3.3.7 การสร้างตัวแปรจำนวนการขาย (Creating a Sales Frequency variable)

ในการสร้างตัวแปรจำนวนการขาย ผู้จัดทำได้สร้างตัวแปรนี้แยกสำหรับชุดข้อมูลฝึกและชุดข้อมูลทดสอบ เนื่องจากวัตถุประสงค์ของตัวแปรคือ การแสดงระดับกิจกรรมทางการขายในแต่ละเดือน ซึ่งช่วยให้ตัวแบบสามารถเรียนรู้ความผันผวนของยอดขายได้ดีขึ้น

ชุดข้อมูลฝึก: ตัวแปรจำนวนการขายถูกสร้างจากการนับจำนวนการขายจริงในแต่ละเดือนโดยตรง

ชุดข้อมูลทดสอบ: ไม่สามารถใช้การนับจำนวนการขายจริงเหมือนชุดข้อมูลฝึก เนื่องจากจะเกิดปัญหาการรั่วไหลของข้อมูล ทำให้ตัวแบบได้รับข้อมูลอนาคตก่อนเวลา ดังนั้น ตัวแปรจำนวนการขายสำหรับชุดทดสอบจะถูกกำหนดตามผลการพยากรณ์ที่ได้จากตัวแบบ

วิธีการนี้ช่วยให้การประเมินประสิทธิภาพของตัวแบบสะท้อนความสามารถในการพยากรณ์จริงโดยไม่ถูกข้อมูลในอนาคตชี้นำ ผลลัพธ์ที่ได้จึงมีความน่าเชื่อถือและเหมาะสมต่อการวิเคราะห์ต่อไป

3.4 การเลือกตัวแบบและพยากรณ์

ในขั้นตอนนี้จะทำการนำชุดข้อมูลที่เตรียมไว้มาสร้างและฝึกตัวแบบเพื่อทำการพยากรณ์ โดยมีการเปรียบเทียบประสิทธิภาพระหว่างตัวแบบ Prophet และ SARIMAX

3.4.1 การตั้งค่าพารามิเตอร์และการฝึกตัวแบบ

การตั้งค่าพารามิเตอร์ของตัวแบบ Prophet

ตาราง 3.6 ค่าพารามิเตอร์ที่กำหนดของตัวแบบ Prophet

พารามิเตอร์	ค่าที่ใช้	รายละเอียด
growth	"linear"	กำหนดให้ตัวแบบมีแนวโน้มการเติบโตเป็นเส้นตรง
changepoint_prior_scale	0.1	กำหนดความยืดหยุ่นของแนวโน้ม ค่า 0.1 ทำให้ตัวแบบจัดการเปลี่ยนแปลงแนวโน้มที่สำคัญโดยไม่ overfit กับ ความแปรปรวนแบบสุ่ม (noise) ของข้อมูล
seasonality_mode	"additive"	รูปแบบของฤดูกาลแบบบวก ซึ่งผลของฤดูกาลจะมีขนาดเท่ากันตลอด
interval_width	0.75	ค่าความเชื่อมั่นของค่าพยากรณ์

การตั้งค่าพารามิเตอร์ของตัวแบบ SARIMAX

ตาราง 3.7 ค่าพารามิเตอร์ที่กำหนดของตัวแบบ SARIMAX

พารามิเตอร์	ค่าที่ใช้	รายละเอียด
endog	y_train	ตัวแปรตาม สำหรับการเรียนรู้ของตัวแบบ (ยอดขายรายเดือน)
exog	X_train	ตัวแปรอิสระภายนอก ที่อาจจะส่งผลต่อตัวแปรตาม
order	(0, 0, 0) (auto_arima)	โครงสร้างของ ARIMA โดยค่า $AR = 0$, $I = 0$, $MA = 0$
seasonal_order	(0, 0, 0, 12) (auto_arima)	โครงสร้างของส่วนฤดูกาล โดยมีค่า $SAR = 0$, $SI = 0$, $SMA = 0$ ของฤดูกาลเท่ากับ 12
enforce_stationarity	False	ไม่บังคับให้ตัวแบบทำให้ข้อมูลอยู่ในแนวโน้มคงที่ เพื่อให้ตัวแบบเรียนรู้

		ข้อมูลที่มีการเปลี่ยนแปลงได้ยืดหยุ่นมากขึ้น
enforce_invertibility	False	ไม่จำกัดโครงสร้างตัวแบบให้อยู่ในรูปแบบที่ง่ายเกินไป เพื่อให้สามารถจับรูปแบบความผันผวนที่ซับซ้อนได้ดีกว่า

การตั้งค่าพารามิเตอร์และการฝึกตัวแบบทั้งสองประเภทนี้ช่วยให้สามารถพยากรณ์ยอดขายรายเดือนได้อย่างแม่นยำ โดยในขั้นตอนของตัวแบบ SARIMAX ได้มีการใช้เทคนิค Auto ARIMA เพื่อค้นหาค่าพารามิเตอร์ที่เหมาะสมที่สุดจากข้อมูลจริง ทำให้ตัวแบบสามารถจับรูปแบบแนวโน้มและความสัมพันธ์เชิงเวลาได้อย่างมีประสิทธิภาพ

นอกจากนี้ ยังมีการนำตัวแปรภายนอกที่ได้สร้างไว้ก่อนหน้านี้ ได้แก่ ตัวแปรฤดูกาล ตัวแปรจำนวนการขาย และตัวแปรเหตุการณ์พิเศษเข้ามาช่วยเสริมความสามารถในการเรียนรู้ของตัวแบบ เพื่อเพิ่มความแม่นยำในการพยากรณ์ยอดขายตามลักษณะของข้อมูลจริงมากยิ่งขึ้น

3.4.2 การพยากรณ์ยอดขาย

หลังจากทำการฝึกตัวแบบด้วยข้อมูลช่วงปี ค.ศ. 2021–2023 แล้ว ขั้นตอนถัดมาคือ การนำตัวแบบที่ผ่านการฝึกสอนมาใช้ในการพยากรณ์ยอดขายสำหรับปี ค.ศ. 2024 โดยในโครงการนี้ได้ดำเนินการพยากรณ์ด้วยตัวแบบหลักจำนวน 2 แบบ ได้แก่ Prophet และ SARIMAX ซึ่งมีขั้นตอนการดำเนินงานในแต่ละตัวแบบดังแสดงในตาราง 3.8

ตาราง 3.8 ขั้นตอนการพยากรณ์ยอดขายด้วยตัวแบบ Prophet และ SARIMAX

ขั้นตอน	ตัวแบบ Prophet	ตัวแบบ SARIMAX
1. การสร้างชุดข้อมูลสำหรับการพยากรณ์	ทำการสร้างชุดข้อมูลล่วงหน้าทีครอบคลุมช่วงปี ค.ศ. 2024 เพื่อใช้ในการพยากรณ์ยอดขายในอนาคต โดยเพิ่มตัวแปรภายนอกที่เกี่ยวข้อง ได้แก่ ค่าฤดูกาล ความถี่การขายรายเดือน และตัวแปรเหตุการณ์พิเศษ จากนั้นนำข้อมูลดังกล่าวเข้าสู่ตัวแบบเพื่อสร้างค่าพยากรณ์ยอดขายสำหรับช่วงเวลาที่ต้องการ	
2. การคำนวณค่าพยากรณ์และช่วงความเชื่อมั่น (Confidence Interval)	ใช้ฟังก์ชัน <code>model.predict()</code> เพื่อคำนวณค่าพยากรณ์ โดยได้ค่ากลาง (<code>yhat</code>) และช่วงความเชื่อมั่น (<code>yhat_lower</code> , <code>yhat_upper</code>) เพื่อ	ใช้ฟังก์ชัน <code>get_forecast()</code> เพื่อคำนวณค่าพยากรณ์ โดยได้ค่าเฉลี่ยการพยากรณ์ (<code>predicted_mean</code>) และช่วงความเชื่อมั่น (<code>conf_int()</code>)

	บ่งบอระดับความไม่แน่นอนของการพยากรณ์	เพื่อกำหนดขอบเขตของความไม่แน่นอนในแต่ละจุดเวลา
3. การประเมินความแม่นยำของตัวแบบ	เปรียบเทียบค่าพยากรณ์กับค่าจริงของปี 2024 (y_{test}) พร้อมคำนวณค่า RMSE, MAE และ MAPE เพื่อวัดประสิทธิภาพของตัวแบบ	
4. การแสดงผลการทำงานของพยากรณ์	แสดงกราฟเปรียบเทียบระหว่างค่าจริงและค่าพยากรณ์ของยอดขาย พร้อมช่วงความเชื่อมั่น เพื่อให้เห็นแนวโน้มการเปลี่ยนแปลงของยอดขายและผลกระทบของตัวแปรภายนอกในแต่ละช่วงเวลา	

จาก ตาราง 3.8 จะเห็นได้ว่า ทั้งสองตัวแบบมีขั้นตอนการพยากรณ์ที่คล้ายคลึงกัน โดยมีความแตกต่างหลัก ๆ อยู่ที่โครงสร้างของตัวแบบและวิธีการจัดการกับตัวแปรภายนอก ซึ่ง Prophet จะเน้นการจำลองแนวโน้มและฤดูกาลด้วยวิธีการเพิ่มองค์ประกอบเชิงฟังก์ชัน ส่วน SARIMAX จะใช้โครงสร้างสมการเชิงเวลาแบบ ARIMA ที่ผสมกับตัวแปรภายนอก เพื่อจับความสัมพันธ์เชิงสาเหตุได้อย่างยืดหยุ่นมากขึ้น

3.5 การประเมินประสิทธิภาพของตัวแบบ

ในขั้นตอนนี้ได้ทำการประเมินประสิทธิภาพของตัวแบบพยากรณ์ยอดขาย ได้แก่ Prophet และ SARIMAX เพื่อเปรียบเทียบความแม่นยำของการพยากรณ์ โดยใช้ชุดข้อมูลทดสอบของปี ค.ศ. 2024 ซึ่งเป็นข้อมูลที่ไม่ได้ใช้ในการฝึกสอนตัวแบบ เพื่อทดสอบความสามารถในการพยากรณ์ค่าข้อมูลที่ไม่เคยพบมาก่อน

การประเมินผลจะดำเนินการโดยคำนวณค่าความคลาดเคลื่อนระหว่างค่าพยากรณ์ และค่าจริง ผ่านตัวชี้วัดทางสถิติหลัก 3 ตัว ได้แก่ RMSE, MAE และ MAPE

3.5.1. ตัวชี้วัดประสิทธิภาพ (Evaluation Metrics)

ในการประเมินประสิทธิภาพของตัวแบบพยากรณ์ยอดขาย เพื่อวัดความคลาดเคลื่อนระหว่างค่าพยากรณ์กับค่าจริง โดยการคำนวณและหลักการของแต่ละตัวชี้วัด

3.5.2. การเปรียบเทียบประสิทธิภาพของตัวแบบ

นำค่าตัวชี้วัดทั้งสามมาเปรียบเทียบระหว่างตัวแบบ Prophet และ SARIMAX ตัวแบบที่มีค่า RMSE, MAE, MAPE ต่ำที่สุด ถือว่ามีความแม่นยำสูงสุดในการพยากรณ์ยอดขาย เนื่องจากค่าที่ต่ำ


สะท้อนถึงขนาดความคลาดเคลื่อนระหว่างค่าพยากรณ์และค่าจริงที่น้อยที่สุด ทำให้ตัวแบบสามารถพยากรณ์ข้อมูลได้ใกล้เคียงกับค่าจริงมากที่สุด

3.6 การพยากรณ์ยอดขายล่วงหน้า

หลังจากได้ทำการประเมินประสิทธิภาพของตัวแบบการพยากรณ์ยอดขายในหัวข้อก่อนหน้านี้ ตัวแบบที่มีค่าตัวชี้วัดความคลาดเคลื่อน ได้แก่ RMSE, MAE และ MAPE ต่ำที่สุด จะถูกเลือกมาใช้ในการพยากรณ์ยอดขายล่วงหน้าในขั้นตอนนี้

การพยากรณ์ยอดขายล่วงหน้าจะดำเนินการโดยใช้ข้อมูลยอดขายย้อนหลังตั้งแต่เดือน มกราคม ค.ศ. 2021 ถึงเดือน ธันวาคม ค.ศ. 2024 เพื่อสร้างตัวแบบที่สามารถสะท้อนแนวโน้ม และรูปแบบตามฤดูกาลของข้อมูลได้อย่างครบถ้วน จากนั้นจะนำตัวแบบที่ผ่านการคัดเลือกมาทำการพยากรณ์ยอดขายในปี ค.ศ. 2025

3.7 ฟังก์ชันกระบวนการดำเนินงาน



ภาพที่ 3.3 แผนผังกระบวนการดำเนินงาน

บทที่ 4 ผลการวิเคราะห์ข้อมูล

บทนี้จะนำเสนอผลการวิเคราะห์ข้อมูลยอดขายเบื้องต้น ผลการตั้งค่าพารามิเตอร์ และผลการประเมินประสิทธิภาพของตัวแบบพยากรณ์ เพื่อให้ได้ข้อสรุปเกี่ยวกับการเลือกตัวแบบที่เหมาะสมที่สุดสำหรับการพยากรณ์ยอดขาย ผลที่ได้จากการพยากรณ์ในโครงการนี้เป็น การเปรียบเทียบผลลัพธ์ระหว่างตัวแบบ Prophet และ SARIMAX ซึ่งได้ทำการฝึกสอนด้วยข้อมูลยอดขายในช่วงปี ค.ศ. 2021–2023 และนำไปใช้พยากรณ์ยอดขายของปี ค.ศ. 2024 โดยมีวัตถุประสงค์เพื่อประเมินความสามารถของแต่ละตัวแบบในการคาดการณ์แนวโน้มยอดขายในอนาคตได้อย่างแม่นยำ

4.1 ผลจากการพยากรณ์ที่ได้จากตัวแบบ Prophet

การทดลองในส่วนนี้เป็นการประเมินประสิทธิภาพของตัวแบบ Prophet ในการพยากรณ์ยอดขายรายเดือน โดยพิจารณาผลของการเพิ่มตัวแปรภายนอก เข้ามาช่วยในการอธิบายแนวโน้มของยอดขาย เพื่อเปรียบเทียบว่าการเพิ่มตัวแปรใดให้ผลลัพธ์ที่มีความแม่นยำสูงสุด ตัวแบบได้ถูกทดสอบภายใต้เงื่อนไขที่ต่างกัน ได้แก่ การใช้ตัวแปรฤดูกาล ตัวแปรวันหยุด ตัวแปรจำนวนการขาย และการผสมกันของตัวแปรทั้งสามในรูปแบบต่าง ๆ ผลการประเมินค่าความคลาดเคลื่อนของตัวแบบในแต่ละกรณีแสดงดังตาราง 4.1

ตาราง 4.1 ค่าการประเมินประสิทธิภาพของตัวแบบ Prophet เพิ่มตัวแปรภายนอก

ตัวแบบ	ตัวแปรภายนอก	RMSE	MAE	MAPE
Prophet	seasonal	424,877.58	370,998.00	85.04%
	holidays	293,867.07	251,532.72	56.30%
	sales_count	266,050.61	229,886.36	54.00%
	seasonal+holidays	255,608.35	216,305.22	48.86%
	seasonal+sales_count	273,200.73	234,780.32	54.67%
	holidays + sales_count	224,624.64	182,695.52	43.73%
	seasonal+holidays+sales_count	223,727.26	181,663.86	43.55%

จาก ตาราง 4.1 พบว่า การเพิ่มตัวแปรภายนอกช่วยให้ประสิทธิภาพของตัวแบบ Prophet ดีขึ้นอย่างชัดเจน โดยตัวแบบที่รวมตัวแปร seasonal + holidays + sales_count ให้ค่าความคลาดเคลื่อนต่ำที่สุดคือ RMSE เท่ากับ 223,727.26, MAE เท่ากับ 181,663.86 และ MAPE เท่ากับ 43.55% แสดงให้เห็นว่า การนำตัวแปรภายนอกทั้งสามตัวเข้ามาช่วยอธิบายแนวโน้มยอดขาย ทำให้ตัวแบบสามารถพยากรณ์ได้อย่างแม่นยำกว่าการใช้เฉพาะปัจจัยฤดูกาลหรือวันหยุดเพียงอย่างเดียว

4.1.1 ผลการประเมินประสิทธิภาพของตัวแบบ

ตาราง 4.2 ค่าการประเมินประสิทธิภาพที่น้อยที่สุดของตัวแบบ Prophet เมื่อใช้ร่วมกับตัวแปรภายนอก

ตัววัดประสิทธิภาพตัวแบบ	ค่าวัดประสิทธิภาพตัวแบบ
RMSE	223,727.26
MAE	181,663.86
MAPE	43.55%

จากผลการประเมิน พบว่าตัวแบบ Prophet มีค่า MAPE เท่ากับ 43.55% ซึ่งอยู่ในระดับความแม่นยำปานกลาง โดยมีแนวโน้มว่าตัวแบบสามารถอธิบายทิศทางการเปลี่ยนแปลงของยอดขายได้ แต่ยังมีข้อจำกัดในการจับความผันผวนของยอดขายจริง โดยเฉพาะช่วงที่มียอดขายพุ่งขึ้นอย่างรวดเร็ว


4.1.2 การแสดงผลการพยากรณ์

ผลการพยากรณ์ยอดขายรายเดือนของปี ค.ศ. 2024 แสดงใน ภาพที่ 4.1 โดยที่

- เส้นสีน้ำเงิน คือ ยอดขายจริง
- เส้นสีแดง คือ ค่าพยากรณ์จาก Prophet
- แถบสีเขียว คือ ช่วงความเชื่อมั่น 75%

จากกราฟสามารถสังเกตได้ว่าตัวแบบ Prophet สามารถติดตามแนวโน้มโดยรวมของยอดขายได้ใกล้เคียงกับค่าจริง โดยเฉพาะช่วงกลางปี

แต่ในบางเดือนปลายปี ตัวแบบมีแนวโน้มพยากรณ์ต่ำกว่าค่าจริง อาจเกิดจากผลของปัจจัยภายนอกที่ตัวแบบไม่ได้รับรู้โดยตรง เช่น การส่งเสริมการขายหรือเหตุการณ์เฉพาะช่วงเวลา



ภาพที่ 4.1 กราฟผลการทำนายของตัวแบบ Prophet

4.1.3 สรุปผลการพยากรณ์ด้วย Prophet

ตัวแบบ Prophet สามารถจำลองแนวโน้มและฤดูกาลของยอดขายได้ ถึงแม้ค่า MAPE จะค่อนข้างสูง แต่ตัวแบบยังคงแสดงศักยภาพในการคาดการณ์ทิศทางการเปลี่ยนแปลงยอดขายได้ดี

การเพิ่มตัวแปรภายนอก เช่น จำนวนการขายรายเดือน และเหตุการณ์ยอดขายพุ่ง มีส่วนช่วยให้ตัวแบบเข้าใจพฤติกรรมการขายมากขึ้น ซึ่งผลลัพธ์ที่ได้จาก Prophet นี้จะถูกนำไปเปรียบเทียบกับตัวแบบ SARIMAX ในหัวข้อถัดไป เพื่อพิจารณาตัวแบบที่เหมาะสมที่สุดสำหรับการพยากรณ์ยอดขาย

4.2 ผลจากการพยากรณ์ที่ได้จากตัวแบบ SARIMAX

ตัวแบบ SARIMAX ถูกนำมาใช้เพื่อวิเคราะห์และพยากรณ์ยอดขายรายเดือนของปี ค.ศ. 2024 โดยมีการค้นหาค่าพารามิเตอร์ที่เหมาะสมที่สุดด้วยวิธี Auto ARIMA ซึ่งจะเลือกตัวแบบที่ให้ค่า AIC ต่ำที่สุด เพื่อให้เกิดความสมดุลระหว่างความแม่นยำของตัวแบบและความซับซ้อนของตัวแบบ

4.2.1 การเลือกตัวแบบจากค่า AIC

ตาราง 4.3 ค่าผลลัพธ์จากการประมาณค่าตัวแบบหลายชุดที่ได้จากกระบวนการค้นหาพารามิเตอร์อัตโนมัติ

ลำดับ	ตัวแบบ (p,d,q)(P,D,Q)[s]	ค่า AIC
1	ARIMA(2,0,2)(1,0,1)[12]	1019.192
2	ARIMA(0,0,0)(0,0,0)[12]	1011.610
3	ARIMA(1,0,0)(1,0,0)[12]	1015.405
4	ARIMA(0,0,1)(0,0,1)[12]	1015.872
5	ARIMA(0,0,0)(1,0,0)[12]	1013.608
6	ARIMA(0,0,0)(0,0,1)[12]	1013.591
7	ARIMA(0,0,0)(1,0,1)[12]	1015.591
8	ARIMA(1,0,0)(0,0,0)[12]	1013.421
9	ARIMA(0,0,1)(0,0,0)[12]	1013.928

จากตาราง 4.3 จะเห็นได้ว่าตัวแบบที่ให้ค่า AIC ต่ำที่สุด คือ

$$ARIMA(0,0,0)(0,0,0)[12] \text{ และค่า } AIC = 1011.610$$

ซึ่งเป็นตัวแบบที่มีเฉพาะค่าเฉลี่ย โดยไม่มีส่วนของ AR หรือ MA หมายความว่า ยอดขายในอนาคตมีแนวโน้มใกล้เคียงกับค่าเฉลี่ยของยอดขายในอดีต

4.2.2 ผลการประเมินประสิทธิภาพของตัวแบบ

การทดลองในส่วนนี้เป็นการประเมินประสิทธิภาพของตัวแบบ SARIMAX เพื่อเปรียบเทียบผลของการเพิ่มตัวแปรภายนอก ต่อความแม่นยำของการพยากรณ์ยอดขายรายเดือน โดยเพิ่มตัวแปรภายนอกในรูปแบบต่าง ๆ ได้แก่ ตัวแปรฤดูกาล ตัวแปรวันหยุด ตัวแปรจำนวนการขายรวมถึงการผสมกันของตัวแปรดังกล่าวในหลายรูปแบบ เพื่อทดสอบว่าตัวแบบใดให้ผลลัพธ์ที่มีประสิทธิภาพสูงที่สุดในการพยากรณ์ยอดขาย ผลการประเมินค่าความคลาดเคลื่อนของตัวแบบในแต่ละกรณีแสดงดังตาราง 4.4

ตาราง 4.4 ค่าการประเมินประสิทธิภาพของตัวแบบ SARIMAX เพิ่มตัวแปรภายนอก

ตัวแบบ	ตัวแปรภายนอก	RMSE	MAE	MAPE
SARIMAX	seasonal	558,918.83	529,797.06	109.35%
	holidays	574,192.38	529,797.06	100.00%
	sales_count	257,483.40	222,278.04	51.82%
	seasonal+holidays	558,618.41	529,797.06	105.64%
	seasonal+sales_count	227,768.19	191,684.67	43.62%
	holidays + sales_count	249,929.06	211,713.19	48.99%
	seasonal+holidays+sales_count	228,645.73	193,182.45	44.02%

จาก ตาราง 4.4 แสดงผลการประเมินประสิทธิภาพของตัวแบบ SARIMAX เมื่อเพิ่มตัวแปรภายนอก พบว่าตัวแบบที่รวมตัวแปร seasonal + sales_count ให้ผลลัพธ์ที่ดีที่สุด โดยมีค่า RMSE เท่ากับ 227,768.19, MAE เท่ากับ 191,684.67 และ MAPE เท่ากับ 43.62% ซึ่งต่ำกว่าการใช้ตัวแปรภายนอกแบบเดียว แสดงให้เห็นว่าการนำตัวแปรยอดขายย้อนหลัง (sales_count) ช่วยให้ตัวแบบสามารถอธิบายความแปรผันของยอดขายได้อย่างมีประสิทธิภาพมากขึ้น

ตาราง 4.5 แสดงค่าการประเมินประสิทธิภาพที่น้อยที่สุดของตัวแบบ SARIMAX เมื่อใช้ร่วมกับตัวแปรภายนอก

ตัววัดประสิทธิภาพตัวแบบ	ค่าวัดประสิทธิภาพตัวแบบ
RMSE	227,768.19
MAE	191,684.67
MAPE	43.62%


จาก ตาราง 4.5 พบว่า ตัวแบบ SARIMAX มีค่า MAPE เท่ากับ 43.62% ซึ่งยังไม่ดีเท่ากับตัวแบบ Prophet (43.55%) แสดงถึงความแม่นยำที่ต่ำกว่า ในขณะที่ค่า RMSE และ MAE ก็มีค่ามากกว่าตัวแบบ Prophet เช่นกัน

4.2.3 การแสดงผลการพยากรณ์

ผลการพยากรณ์ยอดขายรายเดือนของปี ค.ศ. 2024 ด้วยตัวแบบ SARIMAX แสดงใน ภาพที่ 4.2 โดย

- เส้นสีน้ำเงิน = ยอดขายจริง
- เส้นสีแดง = ค่าพยากรณ์จาก SARIMAX
- แถบสีเทา = ช่วงความเชื่อมั่น 75%

จะเห็นได้ว่าตัวแบบสามารถติดตามแนวโน้มยอดขายโดยรวมได้ค่อนข้างดี โดยมีช่วงความคลาดเคลื่อนที่อยู่ในเกณฑ์ยอมรับได้



ภาพที่ 4.2 กราฟผลการทำนายของตัวแบบ SARIMAX

4.2.4 สรุปผลการพยากรณ์ด้วยตัวแบบ SARIMAX

จากผลการวิเคราะห์การพยากรณ์ พบว่าตัวแบบ SARIMAX ซึ่งได้จากการคัดเลือกด้วยเกณฑ์ค่า AIC ต่ำสุด ยังไม่สามารถให้ค่าพยากรณ์ที่มีความแม่นยำเทียบเท่ากับตัวแบบ Prophet ได้ในทุกตัวชี้วัด ได้แก่ RMSE, MAE และ MAPE อย่างไรก็ตาม ตัวแบบ SARIMAX ซึ่งเป็นตัวแบบเชิงสถิติที่มีโครงสร้างเชิงเส้นและเรียบง่าย ยังคงสามารถสะท้อนแนวโน้มเฉลี่ยของยอดขายได้อย่างเหมาะสม โดยเฉพาะในกรณีที่ข้อมูลมีลักษณะคงที่และไม่ซับซ้อนมากนัก

4.3 ผลการประเมินประสิทธิภาพของตัวแบบ (Model Evaluation Results)

ผลการประเมินประสิทธิภาพของตัวแบบพยากรณ์ยอดขาย โดยใช้ค่าตัวชี้วัดทางสถิติ ได้แก่ MAE, RMSE และ MAPE เพื่อเปรียบเทียบความแม่นยำของตัวแบบ Prophet และ SARIMAX

ตาราง 4.6 แสดงผลการเปรียบเทียบของตัวแบบ Prophet และ SARIMAX

ตัวแบบ	MAE	RSME	MAPE
Prophet	181,663.86	223,727.26	43.55%
SARIMAX	191,684.67	227,768.19	43.62%

4.4 สรุปผลการวิเคราะห์

จากผลการทดลองเปรียบเทียบประสิทธิภาพของตัวแบบการพยากรณ์ยอดขายระหว่างตัวแบบ Prophet และตัวแบบ SARIMAX พบว่า ตัวแบบ Prophet ให้ค่า MAE และค่า RMSE ต่ำกว่าตัวแบบ SARIMAX โดยตัวแบบ Prophet มีค่า MAE เท่ากับ 181,663.86 และค่า RMSE เท่ากับ

223,727.26 ขณะที่ตัวแบบ SARIMAX มีค่า MAE เท่ากับ 191,684.67 และค่า RMSE เท่ากับ 227,768.19


นอกจากนี้ ค่า MAPE ของตัวแบบ Prophet อยู่ที่ 43.55% ซึ่งต่ำกว่าตัวแบบ SARIMAX ที่มีค่าเท่ากับ 43.62% แสดงให้เห็นว่าตัวแบบ Prophet สามารถพยากรณ์ยอดขายได้อย่างมีประสิทธิภาพและมีความแม่นยำสูงกว่าตัวแบบ SARIMAX

จากผลการวิเคราะห์พบว่า ตัวแบบ Prophet มีประสิทธิภาพในการพยากรณ์เพิ่มขึ้นอย่างชัดเจนเมื่อเพิ่มตัวแปรภายนอก ได้แก่ ตัวแปรฤดูกาล ตัวแปรจำนวนการขาย และ ตัวแปรวันหยุดเข้ามาในตัวแบบ เนื่องจากทั้งสองตัวแปรสามารถช่วยอธิบายความผันผวนของยอดขายที่เกิดขึ้นตามช่วงเวลาและเหตุการณ์สำคัญได้อย่างเหมาะสม ในขณะที่ตัวแบบ SARIMAX พบว่าเฉพาะ ตัวแปรจำนวนการขายเท่านั้นที่ส่งผลให้ประสิทธิภาพของการพยากรณ์ดีขึ้น แสดงให้เห็นว่าตัวแบบ SARIMAX เหมาะกับข้อมูลที่เป็นตัวเลขต่อเนื่องมากกว่าข้อมูลที่เกิดขึ้นเฉพาะช่วงเหตุการณ์ เช่น วันหยุดหรือเทศกาล

โดยสรุปผลการวิเคราะห์ชี้ให้เห็นว่า ตัวแบบ Prophet มีความเหมาะสมต่อการนำไปใช้พยากรณ์ยอดขายของบริษัท ABC จำกัด มากกว่า เนื่องจากมีค่าความคลาดเคลื่อนโดยรวมต่ำกว่า และสามารถให้ผลการพยากรณ์ที่แม่นยำกว่าทั้งในด้าน MAE, RMSE และ MAPE จึงได้เลือกตัวแบบ Prophet ซึ่งเป็นตัวแบบที่ให้ค่าความคลาดเคลื่อนต่ำที่สุด และมีความแม่นยำสูงกว่าตัวแบบ SARIMAX มาใช้ในการพยากรณ์ยอดขายล่วงหน้า เพื่อศึกษาทิศทางแนวโน้มของยอดขายในอนาคต

ในขั้นตอนนี้ได้ทำการรันตัวแบบ Prophet โดยใช้ข้อมูลยอดขายตั้งแต่เดือนมกราคม ค.ศ. 2021 ถึงเดือนธันวาคม ค.ศ. 2024 เพื่อให้ตัวแบบสามารถเรียนรู้แนวโน้มและลักษณะฤดูกาล ของข้อมูลได้อย่างครบถ้วน จากนั้นจึงทำการพยากรณ์ยอดขายล่วงหน้าในช่วงเดือนมกราคมถึงเดือนธันวาคม ค.ศ. 2025

ผลการพยากรณ์ถูกนำเสนอในรูปแบบกราฟแสดงแนวโน้มยอดขายในอนาคต ดังที่แสดงในภาพที่ 4.3 โดยเปรียบเทียบระหว่างค่าที่คาดการณ์กับข้อมูลจริงในอดีตเพื่อให้เห็นภาพรวมของการเปลี่ยนแปลงของยอดขายอย่างชัดเจน ซึ่งจะช่วยสนับสนุนการวางแผนทางธุรกิจและการบริหารจัดการสินค้าคงคลังของบริษัทได้อย่างมีประสิทธิภาพมากยิ่งขึ้น



ภาพที่ 4.3 กราฟผลการพยากรณ์ยอดขายล่วงหน้าของตัวแบบ Prophet

บทที่ 5 สรุปผลการวิจัย

บทนี้เป็นการนำเสนอผลสรุปจากการดำเนินการวิจัยทั้งหมด ซึ่งประกอบด้วยการสรุปผลการวิเคราะห์ อภิปรายผล และข้อเสนอแนะจากการศึกษา เพื่อสะท้อนให้เห็นถึงประสิทธิภาพของตัวแบบที่ใช้ในการพยากรณ์ยอดขายของบริษัท ABC จำกัด รวมถึงแนวทางในการนำผลลัพธ์ไปประยุกต์ใช้ และข้อเสนอแนะสำหรับการศึกษาต่อไปในอนาคต

5.1 สรุปผลการวิจัย

การศึกษานี้มีวัตถุประสงค์เพื่อพัฒนาตัวแบบการพยากรณ์ยอดขายของบริษัท ABC จำกัด โดยเปรียบเทียบประสิทธิภาพระหว่างตัวแบบ Prophet และตัวแบบ SARIMAX จากข้อมูลยอดขายในช่วงปี ค.ศ. 2021-2024 เพื่อหาตัวแบบที่มีความแม่นยำสูงและเหมาะสมสำหรับการนำไปใช้พยากรณ์ยอดขายในอนาคต

ผลการวิเคราะห์พบว่า ตัวแบบ Prophet มีประสิทธิภาพสูงกว่าตัวแบบ SARIMAX โดยมีค่าความคลาดเคลื่อนเฉลี่ย (MAE) เท่ากับ 181,663.86 และค่ารากที่สองของความคลาดเคลื่อนกำลังสองเฉลี่ย (RMSE) เท่ากับ 223,727.26 ขณะที่ตัวแบบ SARIMAX มีค่า MAE เท่ากับ 191,684.67 และค่า RMSE เท่ากับ 227,768.19 นอกจากนี้ ตัวแบบ Prophet ยังมีค่าร้อยละความคลาดเคลื่อนสัมบูรณ์เฉลี่ย (MAPE) ต่ำกว่าที่ 43.55% เมื่อเทียบกับตัวแบบ SARIMAX ที่มีค่า 43.62%

จากผลลัพธ์ดังกล่าวสามารถสรุปได้ว่า ตัวแบบ Prophet มีประสิทธิภาพสูงกว่าตัวแบบ SARIMAX ทั้งในด้านค่า MAE RMSE และค่า MAPE จึงเหมาะสมกว่าในการนำไปสร้างตัวแบบการพยากรณ์ยอดขายของบริษัท ABC จำกัด สำหรับการประเมินแนวโน้มยอดขายและการวางแผนเชิงกลยุทธ์ในอนาคต

5.2 ข้อจำกัดของการวิจัย

การศึกษานี้มีข้อจำกัดในด้านปริมาณและช่วงเวลาของข้อมูลที่ใช้ในการวิเคราะห์ โดยครอบคลุมเพียง 4 ปี ซึ่งอาจไม่เพียงพอต่อการสะท้อนแนวโน้มการเปลี่ยนแปลงในระยะยาวได้อย่างครบถ้วน แม้ว่าการวิเคราะห์จะได้นำปัจจัยภายนอกจากข้อมูลการขาย เช่น ฤดูกาล จำนวนรายการขาย และวันหยุด มาประกอบการพยากรณ์แล้วก็ตาม แต่ยังไม่ได้รวมปัจจัยทางเศรษฐกิจหรือกิจกรรมส่งเสริมการขาย ซึ่งอาจมีอิทธิพลต่อยอดขายและส่งผลกระทบต่อความแม่นยำของตัวแบบได้ เช่น กัน

5.3 ข้อเสนอแนะ

5.3.1 ข้อเสนอแนะในการนำไปใช้จริง

บริษัทสามารถนำตัวแบบ Prophet ไปประยุกต์ใช้ในการวางแผนการจัดซื้อสินค้า การควบคุมสินค้าคงคลัง และการบริหารงบประมาณได้อย่างมีประสิทธิภาพ เนื่องจากสามารถคาดการณ์ยอดขายล่วงหน้าได้อย่างแม่นยำ ช่วยให้การวางแผนด้านการผลิตและการตลาดเป็นไปอย่างเหมาะสมมากขึ้น และเพิ่มตัวแปรภายนอกอื่น ๆ เช่น โปรโมชั่น หรือกิจกรรมทางการตลาด มาพิจารณาเพิ่มเติมในการพยากรณ์ในอนาคต

5.3.2 ข้อเสนอแนะสำหรับการศึกษาครั้งต่อไป

การศึกษาครั้งต่อไปอาจพิจารณาเพิ่มตัวแปรภายนอกที่มีผลต่อยอดขาย เช่น โปรโมชั่น และปัจจัยทางเศรษฐกิจ เพื่อเพิ่มความแม่นยำในการพยากรณ์ นอกจากนี้ ควรทดลองเปรียบเทียบกับตัวแบบการเรียนรู้ของเครื่องขั้นสูง เช่น XGBoost หรือ LSTM ศึกษาความแตกต่างของประสิทธิภาพในการพยากรณ์ข้อมูลอนุกรมเวลาเชิงซับซ้อน และควรมีการทดสอบตัวแบบกับชุดข้อมูลในช่วงเวลาที่ยาวขึ้น เพื่อประเมินความเสถียรของตัวแบบในระยะยาว

บรรณานุกรม

- เตชินท์ มณีศร, & วนิดา พฤทธิวิทยา. (2020). การสร้างตัวแบบและการพยากรณ์แบบดีวิดท์ที่พร้อมใช้งานตลอดเส้นทางในข่ายงานบริเวณกว้าง [วิทยานิพนธ์ปริญญาโท, มหาวิทยาลัยธรรมศาสตร์].
https://digital.library.tu.ac.th/tu_dc/frontend/Info/item/dc:187122
- Alharbi, F. R., & Csala, D. (2022). A seasonal autoregressive integrated moving average with exogenous factors (SARIMAX) forecasting model-based time series approach. *Inventions*, 7(4), 94.
- Bauer, A. (2021). Automated hybrid time series forecasting: Design, benchmarking, and use cases.
- Brykin, D. (2024). Sales Forecasting Models: Comparison between ARIMA, LSTM and Prophet. *Journal of Computer Science*, 20(10), 1222-1230.
<https://doi.org/10.3844/jcssp.2024.1222.1230>
- Huang, S. (2025) "Prophet with Exogenous Variables for Procurement Demand Prediction under Market Volatility," *Journal of Computer Technology & Applications*, 6(2), 15-20.
- Hyndman, R. J., & Athanasopoulos, G. (2018). *Forecasting: principles and practice*. OTexts. Retrieved from <https://otexts.com/fpp3/>
- Hyndman, R. J., & Khandakar, Y. (2008). Automatic time series forecasting: the forecast package for R. *Journal of statistical software*, 27, 1-22.
- Illukkumbura, A. (2021). *Introduction to time series analysis (Easy Statistics Series)*. Amazon Digital Services.
- Rangan, S., Fletcher, A. K., & Goyal, V. K. Asymptotic Analysis of MAP Estimation via the Replica Method and Applications to Compressed Sensing 2009. *arXiv preprint arXiv:0906.3234*.
- Rupika Priyatham, V., & Ramasree, R. J. (2023). Process of Sales Prediction using ARIMA and SARIMAX to Forecast Future Sales. *International Journal of Scientific Development and Research (IJS DR)*, 8(4), 2183-2190.

- Sharma, K., Bhalla, R., & Ganesan, G. (2022). Time Series Forecasting Using FB-Prophet. CEUR Workshop Proceedings. Retrieved from https://ceur-ws.org/Vol-3445/PAPER_07.pdf
- Taylor, S. J., & Letham, B. (2018). Forecasting at scale. *The American Statistician*, 72(1), 37-45.

ภาคผนวก

ภาคผนวก ก

ตัวอย่างข้อมูลที่ใช้ในการวิจัย

ตัวอย่างข้อมูลก่อนการเตรียมข้อมูล

	doc_id	date	grandtotal
0	A0000001180842983	4-Jan-2021	2495.99
1	A0000001180842983	4-Jan-2021	2495.99
2	A0000001441212458	4-Jan-2021	7337.46
3	A0000001441212458	4-Jan-2021	7337.46
4	A0000003688093889	4-Jan-2021	4446.00
...	...	...	...
4495	A0000471240095838	24-Dec-2024	6420.00
4496	A0000486364972614	24-Dec-2024	6441.40
4497	A0000487283266838	25-Dec-2024	1455.20
4498	A0000476151034756	26-Dec-2024	11556.00
4499	A0000488603041738	26-Dec-2024	1070.00

4500 rows × 3 columns

จะเห็นได้อย่างชัดเจนว่ามีข้อมูลซ้ำหลายจุดในชุดข้อมูล จึงจำเป็นต้องจัดการกับข้อมูลซ้ำเหล่านี้ โดยการคัดเลือกเฉพาะข้อมูลที่มี doc_id ไม่ซ้ำกัน เพื่อให้แต่ละแถวแทนรายการขายจริงเพียงครั้งเดียว

ตัวอย่างข้อมูลหลังการลบข้อมูลซ้ำ

	doc_id	date	grandtotal
0	A0000001180842983	4-Jan-2021	2495.99
2	A0000001441212458	4-Jan-2021	7337.46
4	A0000003688093889	4-Jan-2021	4446.00
8	A0000004195233183	5-Jan-2021	22122.25
11	A0000007327882229	5-Jan-2021	6018.75
...	...	...	...
4494	A0000486364972614	24-Dec-2024	6441.40
4495	A0000471240095838	24-Dec-2024	6420.00
4497	A0000487283266838	25-Dec-2024	1455.20
4498	A0000476151034756	26-Dec-2024	11556.00
4499	A0000488603041738	26-Dec-2024	1070.00

2679 rows × 3 columns

กระบวนการจัดกลุ่มข้อมูล(Data Aggregation)

```
# --- Aggregate monthly sales ---
monthly_sales = df.resample("MS", on="date")["grandtotal"].sum().reset_index()
monthly_sales.columns = ["ds", "y"]
```

หลังจากขั้นตอนการทำความสะอาดข้อมูล ได้ทำการนำตัวแปรวันที่(date) และ ยอดขาย(grandtotal) รวมกลุ่มข้อมูลเป็นรายเดือน และเปลี่ยนชื่อคอลัมน์ดังนี้ วันที่(ds) ยอดขาย(y)

ตัวอย่างข้อมูลหลังกระบวนการจัดกลุ่มข้อมูล

	ds	y
0	2021-01-01	1246312.24
1	2021-02-01	874334.39
2	2021-03-01	1487429.07
3	2021-04-01	602975.65
4	2021-05-01	912745.93
5	2021-06-01	689831.18

กระบวนการสร้างตัวแปรภายนอก

ตัวแปร seasonal

```
# --- Seasonal decomposition (extract seasonal component) ---
log_monthly_sales = df.groupby(df['date'].dt.to_period('M'))['grandtotal'].sum()
log_monthly_sales.index = log_monthly_sales.index.to_timestamp()
result = seasonal_decompose(log_monthly_sales, model='additive', period=12)
seasonal = result.seasonal.reset_index()
seasonal.columns = ["ds", "seasonal"]
monthly_sales = monthly_sales.merge(seasonal, on="ds", how="left")
```

ทำการสร้างตัวแปร seasonal ด้วยกระบวนการแยกองค์ประกอบ (Decompose) เพื่อดึงค่า seasonal ที่ได้นำไปสร้างข้อมูลฤดูกาล หลังจากนั้นได้ทำการรวมข้อมูล seasonal เข้ากับข้อมูล ยอดขายรายเดือน

ตัวอย่างข้อมูลหลังกระบวนการสร้างตัวแปร seasonal

	ds	y	seasonal
0	2021-01-01	1246312.24	4840.424398
1	2021-02-01	874334.39	-185603.387130
2	2021-03-01	1487429.07	186935.857037
3	2021-04-01	602975.65	-255710.010185
4	2021-05-01	912745.93	280416.973565
5	2021-06-01	689831.18	66096.806204
6	2021-07-01	750220.17	70119.444259
7	2021-08-01	861779.59	175026.648565
8	2021-09-01	825589.28	-151654.159769
9	2021-10-01	589280.36	-281904.330463
10	2021-11-01	803042.42	-14125.599352
11	2021-12-01	966347.73	105561.332870

ตัวแปร sales_count สำหรับชุดข้อมูลฝึก

```
# --- Sales Count (Train) ---
monthly_count = df.resample("MS", on="date")["grandtotal"].count().reset_index()
monthly_count.columns = ["ds", "sales_count"]
monthly_sales = monthly_sales.merge(monthly_count, on="ds", how="left")
```

ทำการนับข้อมูลการขายรายเดือนในแต่ละเดือน เพื่อสร้างข้อมูล sales_count หลังจากนั้นได้ทำการรวมข้อมูล sales_count เข้ากับข้อมูลยอดขายรายเดือน

ตัวอย่างข้อมูลหลังกระบวนการสร้างตัวแปร sales_count

	ds	y	seasonal	sales_count
0	2021-01-01	1246312.24	4840.424398	88
1	2021-02-01	874334.39	-185603.387130	58
2	2021-03-01	1487429.07	186935.857037	104
3	2021-04-01	602975.65	-255710.010185	59
4	2021-05-01	912745.93	280416.973565	74
5	2021-06-01	689831.18	66096.806204	64
6	2021-07-01	750220.17	70119.444259	59
7	2021-08-01	861779.59	175026.648565	59
8	2021-09-01	825589.28	-151654.159769	63
9	2021-10-01	589280.36	-281904.330463	60
10	2021-11-01	803042.42	-14125.599352	70
11	2021-12-01	966347.73	105561.332870	68

ตัวแปร sales_count สำหรับชุดข้อมูลทดสอบ

```
#Forecast sales_count (Test Dataset)
count_train = monthly_count[monthly_count["ds"].dt.year <= 2023].copy()

count_model = Prophet(
    growth='linear',
    seasonality_mode='additive')

count_model.fit(count_train.rename(columns={'sales_count': 'y'}))

future_count = count_model.make_future_dataframe(periods=12, freq='MS')
count_forecast = count_model.predict(future_count)[["ds", "yhat"]]
count_forecast.rename(columns={"yhat": "sales_count_forecast"}, inplace=True)

# Merge seasonal & forecasted sales_count into monthly_sales
monthly_sales = monthly_sales.merge(count_forecast, on="ds", how="left")
```

สำหรับข้อมูลชุดทดสอบได้ทำการสร้างตัวแปร sales_count ด้วยกระบวนการพยากรณ์การ ขายรายเดือนด้วยตัวแบบ โดยใช้จำนวนการขายในอดีตให้ตัวแบบเรียนรู้ หลังจากที่ได้ตัวแบบพยากรณ์ จะได้ตัวแปร sales_count_forecast แล้วจึงนำไปรวมเข้ากับข้อมูลยอดขายรายเดือน

ตัวอย่างข้อมูลหลังกระบวนการสร้างตัวแปร sales_count_forecast

	ds	y	seasonal	sales_count	sales_count_forecast
36	2024-01-01	530346.63	4840.424398	46	45.298414
37	2024-02-01	341674.49	-185603.387130	34	60.987050
38	2024-03-01	1129549.89	186935.857037	52	81.167444
39	2024-04-01	259448.16	-255710.010185	28	30.124602
40	2024-05-01	528304.14	280416.973565	40	36.925448
41	2024-06-01	479880.41	66096.806204	38	32.380797
42	2024-07-01	629919.31	70119.444259	33	30.094684
43	2024-08-01	732575.84	175026.648565	31	39.319354
44	2024-09-01	496633.69	-151654.159769	33	36.263887
45	2024-10-01	362557.51	-281904.330463	27	30.320972
46	2024-11-01	529892.52	-14125.599352	31	45.333210
47	2024-12-01	336782.08	105561.332870	40	23.762710

ตัวแปร holidays

```
# --- Holidays ---
threshold = monthly_sales["y"].quantile(0.99)
spike_dates = monthly_sales[monthly_sales["y"] > threshold]["ds"]
monthly_sales["holiday"] = monthly_sales["ds"].isin(spike_dates).astype(int)
```

ตรวจสอบข้อมูลยอดขายที่พุ่งสูงด้วยการใช้เกณฑ์เปอร์เซนไทล์ที่ 99 แล้วนำไปสร้างตัวแปร holidays และนำไปรวมเข้ากับข้อมูลยอดขายรายเดือน

ตัวอย่างข้อมูลหลังกระบวนการสร้างตัวแปร holidays

	ds	y	seasonal	sales_count	sales_count_forecast	holiday
28	2023-05-01	1712289.11	280416.973565	65	59.226613	1

ตัวอย่างข้อมูลหลังกระบวนการสร้างตัวแปรภายนอก

	ds	y	seasonal	sales_count	sales_count_forecast	holiday
0	2021-01-01	1246312.24	4840.424398	88	84.409696	0
1	2021-02-01	874334.39	-185603.387130	58	51.296567	0
2	2021-03-01	1487429.07	186935.857037	104	99.181299	0
3	2021-04-01	602975.65	-255710.010185	59	59.192977	0
4	2021-05-01	912745.93	280416.973565	74	72.829596	0
5	2021-06-01	689831.18	66096.806204	64	67.985236	0
6	2021-07-01	750220.17	70119.444259	59	63.035884	0
7	2021-08-01	861779.59	175026.648565	59	72.843803	0
8	2021-09-01	825589.28	-151654.159769	63	66.635601	0
9	2021-10-01	589280.36	-281904.330463	60	60.444968	0
10	2021-11-01	803042.42	-14125.599352	70	72.364297	0
11	2021-12-01	966347.73	105561.332870	68	61.766215	0

หลังกระบวนการสร้างตัวแปรภายนอกแล้วนำไปรวมกับข้อมูลยอดขาย จะได้ชุดข้อมูลที่พร้อมนำไปสร้างตัวแบบต่อไป

ภาคผนวก ข

คำสั่งภาษาไพธอนที่ใช้ในการวิเคราะห์

ไลบรารีที่ใช้ในโครงงาน

```
import pandas

import numpy

import matplotlib.pyplot

from statsmodels.tsa.seasonal import seasonal_decompose

from prophet import Prophet

from statsmodels.tsa.statespace.sarimax import SARIMAX

from pmdarima import auto_arima

from sklearn.metrics import mean_squared_error, mean_absolute_error
```

คำสั่งสร้างตัวแบบ Prophet

```
# Split train/test sets
train = monthly_sales[monthly_sales["ds"].dt.year <= 2023].copy()
test = monthly_sales[monthly_sales["ds"].dt.year == 2024].copy()

# สำหรับ train ให้ sales_count จริง
train = train.merge(monthly_count, on="ds", how="left", suffixes=("", "_real"))
train["sales_count"] = train["sales_count"]

# สำหรับ test ให้ sales_count จากการพยากรณ์
test["sales_count"] = test["sales_count_forecast"]
```

ขั้นตอนแรก ทำการแบ่งชุดข้อมูลโดย ข้อมูลปี ค.ศ. 2021 - ค.ศ. 2023 เป็นข้อมูลชุดฝึก และ ข้อมูลปี ค.ศ. 2024 เป็นข้อมูลชุดทดสอบ

```
model = Prophet(
    growth="linear",
    changepoint_prior_scale=0.1,
    seasonality_mode="additive",
    holidays=holidays,
    interval_width = 0.75
)

model.add_regressor("seasonal")
model.add_regressor("sales_count")

model.fit(train)
```

กำหนดตัวแบบ Prophet ให้มีรูปแบบแนวโน้มแบบเชิงเส้น พร้อมตั้งค่าพารามิเตอร์ต่างๆ และ เพิ่มตัวแปรภายนอก เพื่อให้ Prophet ใช้ปัจจัยภายนอกที่เกี่ยวข้องกับพฤติกรรมการขายมาช่วย ปรับปรุงความแม่นยำของการพยากรณ์ สุดท้ายทำการฝึกสอนโมเดลด้วยชุดข้อมูลฝึก

```
# --- Create future dataframe for prediction ---
future = model.make_future_dataframe(periods=12, freq="MS")
future = future.merge(seasonal, on="ds", how="left")
future = future.merge(count_forecast[["ds", "sales_count_forecast"]], on="ds", how="left")
future.rename(columns={"sales_count_forecast": "sales_count"}, inplace=True)

# --- Predict ---
forecast = model.predict(future)

# --- Extract forecast results ---
forecast_result = forecast[["ds", "yhat", "yhat_lower", "yhat_upper"]].set_index("ds")
test_result = test.set_index("ds")

# --- Separate train and test forecasts ---
forecast_train = forecast_result.loc[train["ds"]]
forecast_test = forecast_result.loc[test["ds"]]
```

สร้างตารางข้อมูลในอนาคต (future) จำนวน 12 จากนั้นนำข้อมูลตัวแปรภายนอกใส่เข้าไปเพื่อประกอบการพยากรณ์ ก่อนเปลี่ยนชื่อคอลัมน์ sales_count_forecast เป็น sales_count ให้ตรงกับในตัวแบบ จากนั้นให้ตัวแบบสร้างผลพยากรณ์และดึงคอลัมน์สำคัญ ได้แก่ yhat (ค่าพยากรณ์) พร้อมกับ yhat_lower และ yhat_upper ซึ่งเป็นช่วงความเชื่อมั่นของผลลัพธ์

```
# --- Evaluation on 2024 ---
y_true = test_result["y"]
y_pred = forecast_result.loc[test_result.index, "yhat"]
y_lower = forecast_result.loc[test_result.index, "yhat_lower"]
y_upper = forecast_result.loc[test_result.index, "yhat_upper"]

# --- Calculate metrics ---
rmse_test = np.sqrt(mean_squared_error(y_true, y_pred))
mae_test = mean_absolute_error(y_true, y_pred)
mape_test = np.mean(np.abs((y_true - y_pred) / y_true)) * 100

print("==== Forecast Evaluation (2024) Test====")
print(f"RMSE: {rmse_test:.2f}")
print(f"MAE: {mae_test:.2f}")
print(f"MAPE: {mape_test:.2f}%")
```

ดึงข้อมูลจริง (y_true) และค่าพยากรณ์จากตัวแบบ (y_pred) รวมถึงช่วงความเชื่อมั่นของช่วงทดสอบปี 2024 จากนั้นคำนวณตัวชี้วัดความคลาดเคลื่อน ได้แก่ RMSE, MAE, MAPE และแสดงผลลัพธ์ เพื่อใช้ประเมินประสิทธิภาพตัวแบบในการพยากรณ์

```
plt.figure(figsize=(12,6))

# Actual values
plt.plot(test["ds"], test["y"], label="Actual (Test)", color="black", linestyle="--", marker="o")

# Forecasts from Prophet
plt.plot(forecast_test.index, forecast_test["yhat"],
         label="Forecast (Test)", color="red", linestyle="--", marker="x")

# Confidence interval for test period
plt.fill_between(forecast_test.index, forecast_test["yhat_lower"], forecast_test["yhat_upper"],
                 color="green", alpha=0.25,
                 label=f"{int(model.interval_width*100)}% Prediction Interval")

plt.title("Monthly Sales Forecast (Prophet using Predicted Sales_Count)")
plt.xlabel("Date")
plt.ylabel("Sales")
plt.ylim(-1000000, 4000000)
plt.grid(True)
plt.legend()
plt.tight_layout()
plt.show()
```

สร้างกราฟเปรียบเทียบระหว่างยอดขายจริงกับค่าพยากรณ์จากโมเดล Prophet รวมถึงช่วงความเชื่อมั่นของการพยากรณ์ โดยวาดเส้นแทนยอดขายจริงด้วยเส้นประสีดำและจุดวงกลม ค่าพยากรณ์ใช้เส้นประสีแดงและสัญลักษณ์กากบาท นอกจากนี้ ยังมีการแสดงแถบสีเขียวจางเป็นช่วง

ความเชื่อมั่นของผลพยากรณ์ ทำยู่ดตั้งชื่อกราฟ แกนเวลาและยอดขาย รวมถึงช่วงแกน Y เพื่อ
ควบคุมสเกลให้มองเห็นชัดเจน ก่อนแสดงผลพร้อมคำอธิบาย เพื่อความเข้าใจที่ชัดเจนยิ่งขึ้น

คำสั่งสร้างตัวแบบ SARIMAX

```
# Replace actual sales_count in 2024 with forecasted one
monthly_sales.loc[monthly_sales["ds"].dt.year == 2024, "sales_count"] = \
    monthly_sales.loc[monthly_sales["ds"].dt.year == 2024, "sales_count_forecast"]

train = monthly_sales[monthly_sales["ds"].dt.year <= 2023].copy()
test = monthly_sales[monthly_sales["ds"].dt.year == 2024].copy()

y_train = train["y"].values
y_test = test["y"].values

X_train = train[["sales_count", "seasonal"]].values
X_test = test[["sales_count", "seasonal"]].values
```

ขั้นตอนแรกเริ่มจากการแทนที่ตัวแปร sales_count ในปี 2024 ด้วยข้อมูลพยากรณ์ล่วงหน้า (sales_count_forecast) เพื่อใช้เป็นตัวแปรอินพุตสำหรับการทำนายในปีเป้าหมาย จากนั้นทำการแยกชุดข้อมูลตามปี โดยข้อมูลปี ค.ศ. 2021 - ค.ศ. 2023 เป็นข้อมูลชุดฝึก และข้อมูลปี ค.ศ. 2024 เป็นข้อมูลชุดทดสอบ ต่อมาทำการแยกตัวแปรเป้าหมาย (y_train, y_test) ซึ่งแทนยอดขายที่ต้องการพยากรณ์ และตัวแปรภายนอก (X_train, X_test) ซึ่งประกอบด้วยตัวชี้วัดพฤติกรรมการซื้อขาย (sales_count) และตัวแปรฤดูกาล (seasonal) เพื่อใช้เป็นปัจจัยเสริมในการพยากรณ์

```
auto_model = auto_arima(
    y_train, exog=X_train,
    seasonal=True, m=12,
    trace=True, stepwise=True,
    error_action='ignore', suppress_warnings=True
)

print(auto_model.summary())

order = auto_model.order
seasonal_order = auto_model.seasonal_order
print(f"\nBest SARIMA parameters for sales: order={order}, seasonal_order={seasonal_order}")
```

ใช้ฟังก์ชัน auto_arima() เพื่อค้นหาค่าพารามิเตอร์ที่เหมาะสมสำหรับโมเดล SARIMA โดยกำหนดข้อมูลยอดขายเป็นตัวแปรเป้าหมาย (y_train) และใช้ตัวแปรอธิบายภายนอก (X_train) ให้เข้ามาช่วยอธิบายความผันผวนของข้อมูล พร้อมทั้งตั้งค่าพารามิเตอร์อื่นๆ ใช้ m=12 เพื่อระบุว่าข้อมูลมีฤดูกาลรายปี (12 เดือน) ฟังก์ชันจะค้นหาค่าพารามิเตอร์ ARIMA (p, d, q) และ Seasonal ARIMA (P, D, Q, m) หลังการค้นหา จะพิมพ์สรุปตัวแบบ ซึ่งประกอบด้วยค่าพารามิเตอร์และตัวชี้วัดต่าง ๆ จากนั้นดึงพารามิเตอร์ที่ดีที่สุดของโมเดลทั้งส่วนไม่เป็นฤดูกาล (order) และส่วนฤดูกาล (seasonal_order) เพื่อนำไปใช้สร้างตัวแบบต่อไป

```
# Fit SARIMAX with best params
model = SARIMAX(
    y_train,
    exog=X_train,
    order=order,
    seasonal_order=seasonal_order,
    enforce_stationarity=True,
    enforce_invertibility=True,
)

results = model.fit(dispatch=False)

# Forecast for 2024
forecast = results.get_forecast(steps=len(test), exog=X_test)
forecast_mean = forecast.predicted_mean
forecast_ci = forecast.conf_int(alpha=1 - 0.75)
```

สร้างโมเดล SARIMAX โดยใช้พารามิเตอร์ของส่วนไม่เป็นฤดูกาล (order) และฤดูกาล (seasonal_order) ที่ได้มาจาก auto_arima() พร้อมใส่ตัวแปรภายนอก (X_train) และกำหนดพารามิเตอร์ต่างๆ เพื่อบังคับให้ตัวแบบมีความเสถียร หลังจากฝึกโมเดลแล้ว ใช้ get_forecast() เพื่อพยากรณ์ตามขนาดชุดทดสอบ พร้อมส่งตัวแปรภายนอก (X_test) ให้กับตัวแบบ ผลลัพธ์การพยากรณ์ประกอบด้วย forecast_mean คือค่าพยากรณ์ยอดขาย และ forecast_ci ช่วงความเชื่อมั่นร้อยละ 75

```
rmse = np.sqrt(mean_squared_error(y_test, forecast_mean))
mae = mean_absolute_error(y_test, forecast_mean)
mape = np.mean(np.abs((y_test - forecast_mean) / y_test)) * 100

print("==== Evaluation Metrics (2024) =====")
print(f"RMSE: {rmse:,.2f}")
print(f"MAE: {mae:,.2f}")
print(f"MAPE: {mape:,.2f}%")
```

คำนวณตัวชี้วัดความคลาดเคลื่อน ได้แก่ RMSE, MAE, MAPE และแสดงผลลัพธ์ เพื่อใช้ประเมินประสิทธิภาพตัวแบบในการพยากรณ์

```
plt.figure(figsize=(12,6))

# Actual
plt.plot(test["ds"], y_test, label="Actual (Test)", color="black", linestyle="--", marker="o")
# Forecast
plt.plot(test["ds"], forecast_mean_test, label="Forecast (Test)", color="red", linestyle="--", marker="x")
# Confidence intervals
plt.fill_between(test["ds"], forecast_ci_test[:,0], forecast_ci_test[:,1], color="green", alpha=0.25, label="75% Prediction Interval")

plt.title("Monthly Sales Forecast (SARIMAX using Predicted Sales_Count)")
plt.xlabel("Date")
plt.ylabel("Sales")
plt.ylim(-1000000, 4000000)
plt.grid(True)
plt.legend()
plt.tight_layout()
plt.show()
```

สร้างกราฟเปรียบเทียบระหว่างยอดขายจริงกับค่าพยากรณ์จากตัวแบบ SARIMAX รวมถึงช่วงความเชื่อมั่นของการพยากรณ์ โดยวาดเส้นแทนยอดขายจริงด้วยเส้นประสีดำและจุดวงกลม ค่าพยากรณ์ใช้เส้นประสีแดงและสัญลักษณ์กากบาท นอกจากนี้ ยังมีการแสดงแถบสีเขียวจางเป็นช่วงความเชื่อมั่นของผลพยากรณ์ ท้ายสุดตั้งชื่อกราฟ แกนเวลาและยอดขาย รวมถึงช่วงแกน Y เพื่อควบคุมสเกลให้มองเห็นชัดเจน ก่อนแสดงผลพร้อมคำอธิบาย เพื่อความเข้าใจที่ชัดเจนยิ่งขึ้น

ประวัติการศึกษา

ชื่อ-นามสกุล	นายธีรภัทร คำบัวเมือง
วัน เดือน ปีเกิด	วันที่ 12 เมษายน พ.ศ. 2547
ที่อยู่ปัจจุบัน	บ้านเลขที่ 154 ม.11 ตำบลหนองไผ่ อำเภอแก้งคร้อ จังหวัดชัยภูมิ รหัสไปรษณีย์ 36150
ประวัติการศึกษา	
พ.ศ.2559	จบระดับประถมศึกษาปีที่ 6 โรงเรียนบ้านหนองแกหนองโน ตำบลหนองไผ่ อำเภอแก้งคร้อ
พ.ศ.2562	จบระดับมัธยมศึกษาปีที่ 3 โรงเรียนแก้งคร้อวิทยา ตำบลหนองไผ่ อำเภอแก้งคร้อ
พ.ศ.2565	จบระดับมัธยมศึกษาปีที่ 6 (วิทยาศาสตร์-คณิตศาสตร์) โรงเรียนแก้งคร้อวิทยา ตำบลหนองไผ่ อำเภอแก้งคร้อ

ชื่อ-นามสกุล	นายธีรัช ธรรมณี
วัน เดือน ปีเกิด	วันที่ 25 เมษายน พ.ศ. 2547
ที่อยู่ปัจจุบัน	บ้านเลขที่ 234/218 ถนนเทพารักษ์ ตำบลบางพลีใหญ่ อำเภอบางพลี จังหวัดสมุทรปราการ รหัสไปรษณีย์ 10540
ประวัติการศึกษา	
พ.ศ.2559	จบระดับประถมศึกษาปีที่ 6 โรงเรียนสารสาสน์วิเทศสุวรรณภูมิ ตำบลบางพลีใหญ่ อำเภอบางพลี
พ.ศ.2562	จบระดับมัธยมศึกษาปีที่ 3 โรงเรียนสารสาสน์วิเทศสุวรรณภูมิ ตำบลบางพลีใหญ่ อำเภอบางพลี
พ.ศ.2565	จบระดับมัธยมศึกษาปีที่ 6 โรงเรียนสารสาสน์วิเทศสุวรรณภูมิ ตำบลบางพลีใหญ่ อำเภอบางพลี